

스마트 컨테이너 터미널의 시공간 재배치를 위한 강화학습 아키텍처: 독립 제안·수락 정책과 반사실 비용 학습

김건우, 최봉준✉

동서대학교 컴퓨터공학과, 부산, 대한민국
bjchoi@gdsu.dongseo.ac.kr

Abstract. 컨테이너 터미널은 외부 트럭이 도착하기 전에 작업별 야드 블록과 예약시각을 정한다. 그러나 고정된 배정만으로는 이후에 나타나는 혼잡을 반영하기 어렵다. 본 연구는 이미 통지된 작업의 블록과 도착시각을 운영 중에 함께 재검토하는 강화학습 아키텍처를 제안한다. 재배치를 제안하는 정책과 목적 블록 또는 시간대의 수락 정책을 독립적으로 구성하고, 중앙 절차는 양쪽이 동의한 후보 중 자원 제약을 만족하는 것만 확정한다. 작업 하나를 옮기면 해당 작업뿐 아니라 뒤따르는 트럭의 대기, 크레인 작업순서와 선박 공급도 달라진다. 이러한 지연 효과를 반영하기 위해 각 정책은 같은 상태에서 한 행동만 바꾼 이산사건 시뮬레이션 간 비용 차이를 학습한다. 운영 단계에서는 학습된 신경망만 사용한다. 평가는 시간대별 도착 변동은 선행연구를 따르고 일일 수요 수준은 설계값으로 둔 연속 합성환경에서 수행했다. 제안 아키텍처는 재배치 없음보다 총 운영비가 14.7% 낮았다. 또한 같은 시공간 행동 범위를 쓰는 규칙 정책보다 28일 중 20일에서 비용이 낮았다($p = 0.036$). 전체 감소의 91.3%는 도착시각 조정에서, 90.5%는 가장 혼잡한 나홀에서 발생했다. 이 결과는 시공간 재배치가 상시 개입보다 관측된 혼잡에 선택적으로 대응하는 수단으로 더 큰 가치를 가질 수 있음을 보여 준다.


Keywords: 스마트항만, 컨테이너 터미널, 트럭 예약제, 야드 블록 재배치, 반사실 비용 학습, 강화학습

1 서론


컨테이너 물동량은 계속 증가하지만 터미널의 부지와 장비를 같은 속도로 늘리기는 어렵다. 이 제약은 야드와 게이트의 혼잡으로 이어졌고, 스마트항만 연구도 장비 자동화뿐 아니라 운영 의사결정에 주목하게 됐다. 항만 효율 연구에 따르면 자동화, 지능화와 환경 설계는 서로 다른 경로로 성과에 영향을 준다. 따라서 실제 성과는 관측 정보를 운영 판단으로 어떻게 전환하는가에 달려 있다 [1]. 기존 연구는 크게 두 방향으로 발전했다. 시간 측면에서는 트럭 예약제가 도착 피크를 분산하고, 터미널과 운송사가 각자의 비용을 고려해 도착시각을 조정하도록 돕는다 [2, 3]. 공간 측면에서는 컨테이너 배치, 작업순서와 크레인 간섭을 개선해 왔다 [4-7]. 최근에는 강화학습을 실시간 야드 크레인 배치에 적용한 연구도 보고됐다 [8]. 다만 기존 접근은 대체로 트럭 도착 전에 작업 블록과 예약시각이 정해졌다고 가정한다. 이후에는 그 배정 안에서 운영을 개선한다. 그러나 실제 운영 중에는 수요가 특정 시간대나 블록에 집중되고 크레인 대기도 변한다. 처음에는 합리적이었던 배정이 나중에는

비효율적일 수 있는 이유다. 본 연구는 이 고정 배정을 다시 검토한다. 이미 통지된 작업의 배치 장소와 도착시각을 하나의 실시간 의사결정에서 함께 조정한다. 이때 작업 하나의 이동은 뒤따르는 트럭 대기, 크레인 작업순서와 선박 공급까지 바꾼다. 따라서 즉시 이동비만 보아서는 충분하지 않다. 차이 보상과 다중 행위자 반사실 기준선은 한 행동을 대안과 비교하여 이러한 후속 비용을 분리할 수 있다 [9, 10]. 또한 목적 블록이나 시간대가 작업을 받아들일 수 있는지는 제안자의 이익과 별도로 판단해야 한다. 이를 위해 제안과 수락 정책을 분리하고, 중앙 절차가 상호 동의와 실행 가능성을 확인한다. 그림 1은 이 연구의 전체 흐름을 요약한다. 운영 단계에서는 상태를 관측한 뒤 제안, 수락, 확정과 실행이 60초마다 이어진다. 오프라인 학습에서는 같은 상태와 난수 흐름에서 관측 행동과 두 대안을 비교해 제안·수락 비용망의 학습값을 만든다. 따라서 계산량이 큰 반사실 분기는 운영 중에 실행되지 않는다. 세부 정책, 확정 제약과 학습식은 3절에서 설명한다.

(a) Online inference — every 60 s



(b) Offline learning — counterfactual simulation only



Counterfactual branches generate labels offline; online decisions use only the fitted networks.

그림 1: 제안 시스템의 전체 개념. (a) 온라인 운영은 관측된 상태에서 재배치 후보를 제안하고, 목적지가 이를 수락한 뒤, 상호 동의와 용량 조건을 만족한 변경만 확정·실행한다. (b) 오프라인 학습은 같은 상태의 관측 행동과 반사실 대안을 3시간 비교해 두 비용망을 학습한다. 운영 단계에서는 학습된 신경망만 사용한다.

본 연구는 네 가지 질문을 다룬다. 첫째, 독립된 제안·수락 정책으로 시공간 재배치를 구성할 수 있는가? 둘째, 계산량이 큰 반사실 학습을 운영 추론과 분리할 수 있는가? 셋째, 이 아키텍처는 운영비를 줄이는가? 넷째, 관찰된 변화에서 행동 범위와 학습의 기여를 구분할 수 있는가? 주요 기여는 독립 정책 구조, 시공간 행동 범위, 반사실 비용 학습, 학습과 운영의 분리, 그리고 실행·행동 범위·학습 효과를 나누어 보는 분해 가능한 평가다. 2절은 관련 연구를 정리하고, 3절은 제안 구조와 학습 신호를 설명한다. 4절은 실험환경을, 5절은 결과를 제시한다.

2 관련 연구

2.1 스마트항만과 터미널 운영

Yen 등은 자료포락분석으로 항만 효율을 측정한 뒤 그 효율 점수를 스마트항만 설계 속성에 대한 Tobit 회귀로 설명했다. 이 방법은 *항만이 얼마나 효율적인가와 효율 차이를 무엇이 설명하는가*를 구분한다. 또한 자동화, 지능화와 환경 설계가 서로 다른 경로로 작용함을 보여 준다 [1]. 이는 장비 자체뿐 아니라 장비를 활용하는 의사결정 계층을 살펴볼 필요가 있음을 뒷받침한다. 시간 측면에서 Chen 등은 시간창으로 트럭 도착을 관리하여 게이트 혼잡을 완화했다. 이는 용량을 늘리는 대신 도착 분포를 조정하는 접근이다 [2]. Phan과 Kim은 운송사와 터미널이 각자의 비용을 유지한 채 일정과 예약을 조율하는 분산 문제를 다뤘다 [3]. 이 구조는 수락을 하나의 공동 목적함수에 포함하기보다 별도 정책으로 모델링하는 근거를 제공한다. Kourouniotti와 Polydoropoulou는 터미널 집계자료를 이용해 시간대별 트럭 도착 모형을 구축했고, 도착이 하루 동안 균일하지 않음을 보였다 [11]. 따라서 도착시각 조정의 가치는 도착 곡선에서 작업이 어느 구간으로 이동하는가에 달려 있다. 4절의 환경도 이러한 시간대별 변동을 반영한다. 공간 측면에서 Ng와 Mak은 야드 크레인의 작업순서를 최적화하여 트럭 대기를 줄였다 [4]. Speer와 Fischer는 같은 블록에서 여러 크레인이 일할 때 발생하는 간섭을 포함하도록 문제를 확장했다 [5]. Petering과 Murty는 장기 시뮬레이션을 통해 블록 길이와 크레인 배치가 터미널 전체 성능에 미치는 영향을 분석했다 [6]. 본 연구는 여러 주 동안 상태를 이어 가는 이 연속 운영 방식을 따른다. Schwientek 등은 여러 배차 방식을 비교하여 그 상대 성능이 터미널 조건에 따라 달라짐을 보였다 [7]. 따라서 본 연구는 주 실험에서 배차 규칙을 고정하고, 그 민감도를 별도로 확인한다.

2.2 미래비용을 반영한 최적화로서의 강화학습

일반적인 배차 규칙은 주로 행동의 즉시 비용을 기준으로 후보를 비교한다. 그러나 작업 재배치의 영향은 뒤따르는 트럭 대기, 크레인 작업순서와 선박 공급에서 나중에 나타난다. 즉시 이동비만으로는 이러한 효과를 평가하기 어렵다. 강화학습은 현재 행동 이후 일정 지평에서 발생하는 비용을 함께 고려할 수 있다. Wang 등은 PPO 기반 방법을 여러 블록의 실시간 야드 크레인 스케줄링에 적용했다 [8]. 이 연구가 실행 계층의 작업순서를 최적화했다면, 본 연구는 그보다 앞선 블록과 도착시각 배정 계층을 다룬다. 이 관점에서 두 가지 모형 선택이 따른다. 첫째, 신경망은 행동 확률이 아니라 후보 하나에 대한 비용 점수를 출력하고, 정책은 점수가 가장 낮은 후보를 선택한다. 이 점수는 절대 운영비가 아니다. 라벨을 반사실 짝 안에서 중심화하므로(3.4절), 망이 배우는 것은 그 행동이 *비교 대상 행동보다 얼마나 더 싸거나 비싼가*다. 짝의 두 행동에서 같은 상수를 빼기 때문에 후보의 순서는 바뀌지 않는다. 따라서 이 방법은 정책이 아니라 값에 가까운 양을 배운다. 다만 자기 추정을 되먹여 목표를 만드는 심층 Q-신경망 [12]과 달리, 여기서 목표값은 고정된 지평 끝까지 굴러 켜 몬테카를로 비용 차이이다. 둘째, 근사기로 작은 다층퍼셉트론을 사용한다. 다층 순방향 신경망은 일반적인 함수 근사기이지만 [13], 본 연구의 선택은 입력 구조에도 근거한다. 입력은 고정 길이의 수치 특징이며 후보는 하나씩 독립적으로 평가된다. 입력에 순환망이나 주의기제가 활용할 시간 순서가 없고, 라벨 수도 큰 모형을 뒷받침할 만큼 많지 않다. 또한 모든 블록이 하나의 가중치 집합을 공유한다. 이 조건에서는 작은 다층퍼셉트론이 적절한 첫 모형이다. 여러 행위자가 함께

결정하면 미래비용은 공동 결과이므로 각 행동의 기여를 분리하기 어렵다. Wolpert와 Tumer의 차이 보상은 전체 목적과 정렬되면서도 개별 행동에 민감한 보상을 구성한다 [9]. Foerster 등은 중앙 가치모형으로 한 행위자의 행동을 주변화하여 다중 행위자 학습의 반사실 기준선을 만들었다 [10]. 두 방법은 미래 항을 학습된 가치 추정에서 얻는다. 본 연구는 같은 분해 원리를 사용하지만 미래 항을 시뮬레이션으로 직접 측정한다. 같은 상태에서 한 행동만 바꿔 이산사건 시뮬레이터를 다시 실행하고, 고정 지평에 누적된 원화 비용 차이를 회귀 목표로 삼는다. 계산 비용은 오프라인에 집중되지만, 학습 신호는 운영 목적함수와 같은 단위를 유지한다. Kim 등은 건물 수요반응에서 환경 불확실성 아래의 자원 단위 제어에 학습을 적용했다. 이들은 실측 환경 기록과 개별 단위의 변동을 만드는 합성 매개변수를 함께 사용하고, 합성 요소를 명시적으로 구분했다 [14]. 4.1절도 같은 원칙에 따라 문헌에서 가져온 범위와 본 연구의 설계값을 구분한다.

3 제안 아키텍처

그림 2에는 제안 아키텍처의 운영 경로, 터미널 환경과 오프라인 학습 경로가 나타나 있다. 운영 경로는 새로 통지된 작업을 한 번 검토하고, 독립된 제안·수락 정책과 중앙 확정 절차를 거쳐 배정을 바꾼다. 터미널 환경은 그 결정 이후의 트럭 대기, 추가 이동, 재취급과 선박 유틸비용을 계산한다. 학습 경로는 결정 직전의 상태와 난수를 복제해 관측 행동과 반사실 대안을 비교하며, 이 계산은 운영 경로와 분리된다.




그림 2: 제안 아키텍처의 상세 흐름. (a) 운영 단계는 60초마다 자격 확인, 제안, 수락과 확정을 수행하며, 상호 동의나 용량 조건을 만족하지 못하면 원배정을 유지한다. (b) 이산사건 환경은 게이트, 21개 블록, 블록당 야드 크레인 2기와 선박 작업을 연결해 운영비 Φ 를 계산한다. (c) 오프라인 학습은 같은 상태와 난수 흐름에서 최대 세 세계를 3시간 비교해 제안망과 수락망의 비용 라벨을 각각 만든다.

3.1 기호·행동·정책

결정 간격은 $\delta = 60$ 초다. 작업 i 의 현재 배정을 $z_i = (b_i, \tau_i)$ 로 나타내며, b_i 는 블록이고 τ_i 는 통지된 도착예정시각이다. 재배치 행동은 다음과 같다.

$$a_i = (b'_i, \Delta_i) \in \mathcal{A}_i(t), \quad z_i(a_i) = (b'_i, \tau_i + \Delta_i). \quad (1)$$

원배정 유지는 $a_i^0 = (b_i, 0)$ 이다. $b'_i \neq b_i$ 이면 블록을 바꾸고, $\Delta_i > 0$ 이면 도착시각을 늦춘다. 두 값을 함께 바꾸는 후보도 허용한다. 다만 반출 작업은 꺼낼 컨테이너의 위치가 이미 정해져 있으므로 블록 재배치 후보에서 제외한다. 작업의 통지시각을 n_i , 게이트 진입시각을 g_i , 최초 검토 여부를 r_i 라 한다. 작업은 통지될 때가 아니라 도착이 검토 창 안으로 들어올 때 자격을 얻는다. 창은 $w_i = \min(W, \tau_i - n_i)$ 이고 $W = 1800$ 초다. 리드타임이 허락하는 가장 최신 상태에서 결정하기 위해서다.

$$\mathcal{E}_t = \{i \mid w_i - \delta < \tau_i - t \leq w_i, g_i > t, r_i = 0\}. \quad (2)$$

따라서 각 작업은 정확히 한 결정 구간에만 들어오고 다시 검토되지 않는다. 도착보다 W 이상 앞서 통지된 보통 작업은 도착 정확히 W 전에 결정된다. 통지 중앙값보다 약 46분 늦은 시점이며, 정보의 신선함은 여기서 온다. 리드가 그보다 짧은 작업은

통지되는 즉시 검토된다. 도착보다 늦게 통지된 작업은 $w_i = 0$ 이라 자격을 한 번도 얻지 못하는데, 4.3절의 리드타임 분포에서 이런 작업이 수요의 14.1%이며 아키텍처는 그 배정을 건드리지 않는다. 제안 정책은 현재 블록 상태와 작업·행동 특징 o_i^P 를 이용한다. 후보별 비용 점수를 계산하고 가장 낮은 행동을 선택한다(3.3절).

$$\hat{a}_i = \arg \min_{a \in \mathcal{A}_i(t)} \hat{c}_\theta^P(o_i^P, a), \quad p_i = \mathbf{1}[\hat{a}_i \neq a_i^0]. \quad (3)$$

제안이 발생하면 목적 블록 또는 목표 시간대가 수락 주체가 된다. 수락 정책은 제안 메시지와 목적지 상태 o_i^A 를 이용해 수락과 거절의 예상 비용을 비교한다.

$$q_i = \mathbf{1}[\hat{c}_\psi^A(o_i^A, \hat{a}_i, \text{accept}) \leq \hat{c}_\psi^A(o_i^A, \hat{a}_i, \text{reject})]. \quad (4)$$

목표 자원의 남은 용량이 0이면 신경망을 호출하기 전에 거절한다. 두 정책이 모두 동의한 후보의 집합은 $\mathcal{J}_t = \{i \in \mathcal{E}_t \mid p_i q_i = 1\}$ 이다.

3.2 중앙 확정 제약

중앙 절차는 새 후보를 만들지 않으며 $\mathcal{J}_t$ 안에서만 작업을 확정한다. 먼저 동의된 후보를 수락 정책의 예측비용 오름차순으로 정렬한다. 동점이면 작업과 좌표의 사전순을 적용한다. 후보 i 의 확정 여부를 $x_i \in \{0, 1\}$, 목적 블록의 남은 슬롯을 $F_b(t)$, 예약 시간대 k 의 남은 정원을 $K_k(t)$ 라 하면 다음 제약을 만족한다.


$$\begin{aligned} x_i &\leq p_i q_i, & \sum_{i \in \mathcal{J}_t} x_i \mathbf{1}[b'_i = b] &\leq F_b(t), \\ \sum_{i \in \mathcal{J}_t} x_i \mathbf{1}[k(i) = k] &\leq K_k(t), & \sum_{t \in \mathcal{T}} \mathbf{1}[i \in \mathcal{E}_t] &\leq 1. \end{aligned} \quad (5)$$

블록 용량 제약은 모든 실험에서 적용한다. 시간대 정원 자료가 없는 경우에는 $K_k(t) = \infty$ 로 둔다. 따라서 이 조건의 결과는 도착시각 조정이 제공할 수 있는 가능성의 범위로 해석한다. 확정된 배정은 결정 시점이 끝날 때 한꺼번에 반영된다. 먼저 확정된 작업이 같은 시점의 다른 후보가 보는 상태를 바꾸지 않도록 하기 위해서다. 이 구조는 두 조건을 보장한다. 제안과 수락이 모두 있는 후보만 확정되며, 각 작업은 한 번만 검토된다.

3.3 정책모형과 입력

3.1절의 $\hat{c}_\theta^P$ 와 $\hat{c}_\psi^A$ 는 비용 신경망이다. 두 망은 행동 확률을 출력하지 않는다. 관측 상태와 후보 하나를 입력받아 스칼라 비용 점수를 출력한다. 이 점수는 절대 비용이 아니라 짝 중심 상대 비용이다. 학습 전에 반사실 짝의 두 행동을 그 평균으로 중심화 하므로(3.4절), 망은 그 후보가 함께 굴린 비교 대상보다 얼마나 비싼지를 예측한다. 평균 차감은 두 행동에 공통인 상수를 없애는 것이므로 후보의 순위, 따라서 식 (1)의 $\arg \min$ 과 식 (2)의 비교는 달라지지 않는다. 정책은 같은 망으로 모든 후보를 평가한 뒤 학습된 점수의 $\arg \min$ 을 선택한다. 두 모형은 고정 길이 특징을 처리하는 다층퍼셉트론이며, 모든 블록이 같은 가중치를 공유한다. 제안 정책은 21차원, 수락 정책은 16차원 입력을 사용한다. 두 모형의 은닉층은 모두 64-ReLU-64-ReLU이고, 매개변수는 각각 5,633개와 5,313개다. 전체 매개변수는 11,000개보다 적다.

입력에는 현재 대기, 재고, 남은 크레인 작업량, 공개 도착예정시각, 경로 차이와 목표 시각 주변의 통지 물량이 포함된다. 아직 실현되지 않은 실제 도착·완료시각과 다른 수락 주체의 동시 응답은 제외한다. 그림 3은 비용 신경망 하나의 구조를 보여 준다. 후보는 고정 길이 벡터 $x \in \mathbb{R}^{d_{in}}$ 로 입력된다. 벡터는 세 선형층을 지나며, 앞의 두 층 뒤에는 ReLU 활성화함수가 적용된다. 출력은 그 후보의 짝 중심 비용 점수를 나타내는 스칼라 하나다. 이 구조에서는 후보 목록의 길이가 바뀌어도 모형을 다시 학습할 필요가 없다. 또한 모든 블록이 같은 입력 형식과 가중치를 사용한다. 즉 블록별 모형을 따로 배우는 대신, 현재 상태에서 후보를 평가하는 공통 규칙을 학습한다. 두 정책은 입력 차원만 다르며 제안은 21차원, 수락은 16차원이다.



$$\text{MLP}(x) = W_3 \text{ReLU}(W_2 \text{ReLU}(W_1 x + b_1) + b_2) + b_3$$

그림 3: 비용 신경망 하나의 구조. 입력은 후보 하나에 대한 고정 길이 특징 벡터이고 두 개의 64차원 은닉층에는 ReLU 활성화함수를 적용한다. 출력은 그 후보의 짝 중심 비용 점수 하나다. 한 번의 결정은 같은 망으로 후보를 각각 평가한 뒤 $\arg \min$ 을 취한다. 제안 정책과 수락 정책은 이 구조를 공유하며 입력 차원만 각각 21과 16으로 다르다.

3.4 반사실 비용 라벨

각 표본 결정에서 분기 직전의 상태와 난수 흐름을 복제한다. 그런 다음 최대 세 개의 세계를 3시간 동안 실행한다.

$$\begin{aligned} \phi_i^F &= \Phi_H(\text{관측 행동}), & \phi_i^P &= \Phi_H(\text{제안만 반대}), \\ \phi_i^A &= \Phi_H(\text{수락만 반대}), & H &= 10,800 \text{ s}. \end{aligned} \quad (6)$$

대안 세계는 언제나 정책이 실제로 한 행동을 뒤집는다. 제안 정책이 변경을 제안 했으면 대안은 현재 배정을 유지하고, 유지했으면 대안은 현재 가중치에서 가장 싼 후보를 확정한다. 수락 정책의 대안은 수락과 거절을 맞바꾼다. 수락 요청이 없는 결정에서는 제안 비교만 생성한다. 각 정책의 두 행동은 그 짝의 공통 평균을 뺀 뒤 100,000원으로 나누어 학습한다.

$$\bar{\phi}_i^P = \frac{\phi_i^F + \phi_i^P}{2}, \quad y_{i,F}^P = \frac{\phi_i^F - \bar{\phi}_i^P}{100,000}, \quad y_{i,P}^P = \frac{\phi_i^P - \bar{\phi}_i^P}{100,000}. \quad (7)$$

즉 목표값은 짝 비용 차이의 $\pm$ 절반이다. 수락 정책에도 (ϕ_i^F, ϕ_i^A) 를 이용한 같은 중심화를 적용한다. 따라서 기준점은 고정된 어떤 행동이 아니라 짝 자체다. 목표 값은 그 행동이 같은 세계에서 함께 굴린 단 하나의 대안보다 얼마나 좋았는지.

나뉘었는지를 말한다. 평균을 빼면 두 행동의 순서는 유지하면서 두 세계가 공유하는 비용을 제거할 수 있다.

3.5 학습 설정과 운영 분리

하루에 최대 64개 결정을 표본으로 사용한다. 탐색 확률은 0.50에서 0.05까지 선형으로 줄인다. 표본은 결정 단위로 학습 80%와 검증 20%로 나눈다. 최적화에는 Adam(학습률 3×10^{-4})과 Huber 손실($\beta = 1.0$)을 사용한다. 일부 반사실 비용 차이가 다른 표본보다 훨씬 크므로, 제곱오차를 사용하면 소수의 표본이 학습을 지배할 수 있다 [17]. 미니배치는 최대 256행이며 갱신 횟수는 $\max(50, \min(600, 4 \times \text{학습행수}))$ 다. 기울기는 1.0으로 제한한다. 반사실 분기는 여러 CPU 코어에서 병렬로 실행한다. 그날 생성한 라벨은 당일 갱신 뒤 교체한다. 운영 평가에서는 가중치를 고정하고 탐색을 끈다. 반사실 분기도 호출하지 않는다. 따라서 라벨은 고정된 자료가 아니다. 모든 반사실 짝은 그 시점의 정책이 실제로 한 행동에서 갈라져 나오므로, 어떤 상태에 라벨이 붙는지도, 그 상태가 무엇과 비교되는지도 가중치가 바뀌면 함께 움직인다. 한 회차의 라벨은 그 회차의 갱신 뒤 버린다. 이런 점에서 본 학습은 시뮬레이터가 만든 기준선을 쓰는 온폴리시 몬테카를로 이점 추정해 담당한다. 목표값은 지평 끝까지 굴린 완전한 시뮬레이션 결과이며, 부트스트랩도 정책경사도 쓰지 않는다. 두 망을 30회차 학습하는 데 사용한 장비에서 약 18시간이 걸렸다. 운영 단계에서는 후보마다 작은 신경망을 한 번 통과시킨다. 이 계산량은 함께 수행하는 제약 검사에 비해 작다. 따라서 주요 계산 비용은 반사실 라벨 생성에서 발생하며, 이 작업은 오프라인에서만 수행된다.

4 실험환경

4.1 문헌 기반 합성환경

제안 아키텍처는 특정 터미널의 운영기록이 아니라 문헌 기반 합성환경에서 평가한다. 환경의 범위는 2절의 선행연구를 참고했다. 여기에는 20개 블록 [7], 블록별 복수 크레인 [5], 여러 주의 연속 운영 [6], 트럭 도착의 뚜렷한 시간대별 변동 [11], 기항량이 다른 세 선박 등급 [7], 크레인 취급시간 범위 [6]가 포함된다. 이 범위 안에서 본 연구는 21개 블록, 블록당 크레인 2기, 상태가 이어지는 30일 연속 운영, 세 선박 등급과 180초의 기준 크레인 서비스시간을 사용한다. 도착곡선은 4.3절에서 설명한다. 이 값들은 본 연구의 설계 선택이다. 인용문헌은 값이 기존 모형의 범위 안에 있음을 뒷받침하지만, 특정 항만의 운영자료에서 직접 추정했다는 뜻은 아니다.

4.2 터미널과 시간 설정

야드는 21개 블록과 42기의 야드 크레인으로 구성한다. 각 블록에는 크레인 2기를 두고, 용량은 1,440슬롯, 초기 점유율은 65%로 설정한다. 게이트와 안벽은 1차원 야드의 서로 반대쪽에 있으며 결정 간격은 60초다. 운영은 30일 동안 연속으로 진행하고 가운데 28일을 비교한다. 크레인은 실제 서비스 작업을 먼저 처리하고, 그 안에서는 예상 처리시간이 짧은 작업을 우선한다. 하루의 경계는 비용을 구분하는 시점일 뿐 터미널을 초기화하는 시점이 아니다. 야드 재고, 대기열, 크레인 상태와 미완료 작업은 다음 날로 이어진다. 첫날과 마지막날은 이 연속 경계를 연결하는 데 사용한다.

4.3 외부 트럭 작업 수요와 도착 과정

선행연구는 트럭 도착이 하루 중 균일하지 않고 시간대별로 뚜렷하게 변한다는 점을 뒷받침한다 [11]. 일일 수요 수준과 아래의 구체적인 도착곡선은 실험을 위해 설정한 본 연구의 설계값이다. 일일 수요는 {3,500, 5,000, 7,500, 12,500, 15,000} 대 위의 이산분포에서 확률 {0.30, 0.30, 0.25, 0.10, 0.05}로 추첨한다(그림 4a). 앞의 세 수준은 원활, 보통과 높은 수요를 나타내고, 뒤의 두 수준은 혼잡과 초혼잡 조건을 나타낸다. 각 작업의 통지시각은 도착밀도 $f(t)$ 에서 생성한다. 이 밀도는 전체 물량의 38%를 담는 균등 기저와 나머지 62%를 담는 세 개의 가우시안 성분으로 구성한다(그림 4b).

$$f(t) = 0.38 U(0, 24) + 0.62 \sum_{m=1}^3 w_m \mathcal{N}(t; \mu_m, \sigma_m^2), \quad (8)$$

여기서 (μ_m, σ_m, w_m) 은 각각 (10, 1.5, .317), (15, 2.5, .633)와 (21, 1, .05)이고 시간 단위는 시(hour)다. 균등 기저는 야간 도착률을 0보다 크게 유지한다. 따라서 날짜 경계를 넘어 이어지는 야드 상태가 인위적으로 비어 있는 밤의 결과가 되지 않는다. 봉우리의 위치, 폭과 가중치는 수요수준별 혼잡 민감도를 비교하기 위한 설계값이며 특정 터미널에서 추정된 값이 아니다. 학습과 평가는 같은 곡선 형태를 사용한다. 두 단계는 수요 수준과 난수만 다르다. 따라서 형태가 다른 도착곡선에 대한 일반화는 평가하지 않았다.




그림 4: 외부 트럭 작업 수요. (a) 다섯 개의 일일 수요 수준과 각각이 뽑힐 확률이며 날마다 독립으로 추첨한다. (b) 하루 12,500대 조건의 시간대별 도착 과정으로, 균등 기저와 가우시안 성분 셋을 이들이 합쳐 이루는 곡선 아래에 따로 그렸다. 선행연구가 뒷받침하는 것은 도착이 하루 중 균일하지 않다는 사실이며, 수요 수준과 혼합의 형태는 본 연구의 설계값이다.

4.4 선박과 안벽 작업

선박은 소형, 중형과 대형의 세 등급으로 나눈다. 표 1은 등급별 규모, 배정 STS, 유틸비용과 일일 기항 구성을 요약한다.

표 1: 선박 등급과 일일 기항 구성. 기항 비율은 하루 평균 3.3척을 기준으로 계산했다. 대형 0.3척은 매일 30% 확률로 1척을 추가하는 설정의 기대값이다.

등급	GT	TEU	STS (기)	유타비용 (천원/h)	일일 기항 (평균 척수 비율)
소형	50,000	3,000	2	149.5	2.0 (60.6%)
중형	100,000	7,500	4	299.0	1.0 (30.3%)
대형	150,000	14,000	6	448.5	0.3 (9.1%)

용량이 C TEU인 선박의 기항 작업량은 $u \sim U[0.15, 0.30]$ 에 대해 $C \cdot u$ 로 추출한다. STS 1기의 처리율은 27.5 move/h이며, 이는 문헌의 24, 30과 36 move/h 범위 안에 있다 [7]. 배정된 STS에서 발생한 막힘은 합산한 뒤 STS 수로 나누어 선박별 유타시간으로 환산한다. 야드 크레인 1기의 기준 서비스시간은 180초/move이므로 이론상 총 이동능력은 $\mu_{YC} = 21 \times 2 \times 3600/180 = 840$ move/h다. move는 컨테이너 이동 횟수이며 트럭 건수와 다르다. 트럭 작업 하나가 여러 이동과 재취급을 요구할 수 있으므로 두 단위를 구분해 보고한다.

4.5 비용함수

날짜 구간 $[d, d+1)$ 의 총비용은 네 항의 합으로 정의한다.

$$\Phi_d = C_{wait,d} + C_{move,d} + C_{rehandle,d} + C_{vessel,d}. \quad (9)$$

트럭 체류비는 시간당 40,000원이며, 1시간을 넘는 구간에는 같은 단가를 한 번 더 적용한다. 화폐 기준점은 안전운임에서 가져왔고 시간 환산 방식은 본 연구의 설계 값이다 [15]. 추가 크레인 이동은 작업시간당 60,000원, 재취급은 회당 2,000원으로 설정한다. 두 값도 연구 설계값이다. 선박 유타비는 접안 초과요율 29.9원/10GT·시간을 GT·시간당 2.99원으로 환산했다 [16]. 트럭 i 의 체류시간을 h_i , 추가 크레인 작업시간을 m , 재취급 횟수를 R , 선박 v 의 정책 관련 유타시간을 T_v 라 하면 비용은 다음과 같다.

$$\begin{aligned} C_{wait} &= \sum_i 40,000 \{h_i + \max(0, h_i - 1)\}, & C_{move} &= 60,000 m, \\ C_{rehandle} &= 2,000 R, & C_{vessel} &= \sum_v 2.99 GT_v T_v. \end{aligned} \quad (10)$$

접이안과 검역처럼 재배치 정책이 바꿀 수 없는 구조적 선박 시간은 별도 진단값으로 분리한다. 네 비용 항은 같은 날짜 경계에서 측정한 누적값의 차이로 계산한다. 학습에 사용한 30일 실행에서 환경의 두 가지 성질을 확인했다. 첫째, 대기비용이 총비용을 지배한다. C_{wait} 는 96.4%를 차지하며, 재취급은 2.2%, 선박 유타는 1.2%, 추가 크레인 이동은 0.1%다. 따라서 Φ 에 대한 판단은 대부분 안전운임을 화폐 기준점으로 삼아 설정한 트럭 체류비 계수에 의해 결정된다. 문헌값이 아닌 두 설계 계수의 영향은 상대적으로 작다. 둘째, 수요가 증가하면 대기비중과 서비스 수준이 급격히 나빠진다. 대기비중은 하루 3,500대에서 83.2%, 7,500대에서 91.7%, 15,000대에서 99.1%로 증가한다. 한 달 전체의 평균 체류시간은 0.89시간이고 90분위

체류시간은 2.01시간이다. 트럭 작업 206,904건 중 5.0%는 통지된 날 안에 끝나지 않았다. 특히 90분위 체류시간은 가장 한산한 날 0.79시간에서 가장 붐비는 날 7.49시간까지 9.5배 증가했다. 즉 혼잡한 날은 비용 규모뿐 아니라 비용 구성도 다르다. 재배치 정책은 바로 이 차이를 활용해야 한다.

5 실험결과

5.1 결과의 범위

결과는 학습과 겹치지 않는 난수시드 9,900,950의 30일 연속 진단 실행에서 얻었다. 첫날과 마지막날을 제외한 가운데 28일을 비교한다. 평가 중에는 가중치를 고정하고 탐색확률을 0으로 설정했다. 같은 날짜의 모든 정책은 동일한 트럭, 선박과 서비스 난수를 공유한다. 날짜별로 네 비용 항, 수요수준, 거래 유형과 미완료 작업을 저장했다. 소스코드, 정책별 원자료와 그림 생성 스크립트도 함께 공개한다.

5.2 아키텍처 작동 확인

아키텍처의 네 조건은 구현, 확정 제약과 자동 시험으로 확인했다. 제안과 수락은 서로 다른 모형이 판단한다. 한쪽만 동의한 재배치는 확정되지 않는다. 실제 미래 도착·완료시각은 정책 입력에 포함되지 않는다. 또한 날짜 경계에서도 상태가 초기화되지 않는다. 실행 기록에서는 두 조건을 추가로 확인했다. 고정정책 평가 중 반사실 분기 호출은 0회였다. 행동을 바꾸지 않은 분기가 본 실행의 행동과 비용을 재현하는 동일성 검사도 반사실 라벨이 있는 4개 지점에서 모두 통과했다.

5.3 정책별 비용 감소와 날짜 짝비교

이 절에서 학습 정책은 3절 아키텍처 전체(제안·수락·중앙 확정)를 가리키며, 그 두 망 가운데 하나인 제안 정책과 구별한다. 표 2는 28일 총비용을 재배치 없음과 비교한다. 양수는 비용 감소, 음수는 비용 증가를 뜻한다. 전체 순위를 한 줄로 세우지 않고 행동 분해, 학습 여부, 규칙 정책과 기준선 순으로 묶었다.

표 2: 정책별 전체 비용 감소. 감소율은 재배치 없음의 28일 총비용을 기준으로 한다. 양수는 비용 감소, 음수는 비용 증가를 뜻한다.

정책	사용 행동	재배치 없음 대비 감소율
학습 정책	블록 + 시각	+14.72%
학습 정책 (시각만)	시각	+13.44%
학습 정책 (블록만)	블록	-1.31%
학습 전 모형	블록 + 시각	+7.97%
규칙: 한산한 시간대	시각	+3.41%
규칙: 한산한 블록 + 시간대	블록 + 시각	+1.51%
규칙: 최소 여유시간	블록	+0.53%
규칙: 선착순	블록	+0.17%
규칙: 최단 처리시간	블록	+0.05%
규칙: 순이득	블록	-0.48%
재배치 없음	—	0.00%

28일 총비용은 재배치 없음에서 100.0억원, 학습 정책에서 85.2억원이었다. 학습 정책은 14.71억원, 즉 14.7%를 줄였다. 시각 조정만 허용해도 13.44%가 감소했지만 블록 재배치만 허용하면 비용이 1.31% 증가했다. 따라서 전체 감소는 주로 도착 시각 조정에서 발생했다. 시뮬레이션 잡음을 줄이기 위해 모든 정책을 같은 난수 흐름에서 실행했으며, 이는 Kleijnen의 공통 난수 방법을 따른다 [18]. 날짜를 독립 비교 단위로 본다. 짝비교 검정을 둘 보고하는데, 둘이 서로 다른 질문에 답하기 때문이다. 양측 부호검정은 어느 정책이 더 싼 날이 며칠인지만 세므로 하루하루 차이의 크기를 보지 못한다. 윌콕슨 부호순위검정은 차이를 크기 순으로 매긴 뒤 더하므로, 이기는 날은 적어도 크게 이기는 정책을 다르게 채점한다. 이 구분은 본 연구에서 중요하다. 학습 정책은 선택적으로 개입하도록 설계되어, 모든 날 이기는 것이 아니라 혼잡한 날에 비용을 크게 줄이는 것을 목표로 하기 때문이다. 28일에 동점인 날이 없으므로 두 검정 모두 정확검정으로 계산했다. 표 3에 둘 다 적는다.

표 3: 학습 정책과 비교 정책의 날짜별 짝비교. “더 저렴한 날”은 같은 28일 중 학습 정책의 비용이 더 낮았던 날의 수다. 두 p 모두 양측 정확검정이다. 부호검정은 하루하루 차이의 방향만 쓰고, 윌콕슨 부호순위검정은 그 크기까지 쓴다. 0.05 미만은 굵게 표시했다.

비교 목적	비교 정책	학습 정책이 더 저렴한 날	부호검정 p	부호순위 p
학습 효과	학습 전 모형	18/28	0.185	0.164
같은 행동 범위	한산한 블록 + 시간대 규칙	20/28	0.036	0.015
블록 규칙	최소 여유시간	20/28	0.036	<0.001
블록 규칙	선착순	22/28	0.004	<0.001
블록 규칙	최단 처리시간	21/28	0.013	0.006
블록 규칙	순이득	21/28	0.013	0.003
기준선	재배치 없음	26/28	<0.001	<0.001

학습 정책은 같은 블록·시각 행동을 쓰는 규칙보다 28일 중 20일에서 비용이 낮았다 (부호검정 $p = 0.036$, 부호순위 $p = 0.015$). 반면 학습 전 모형보다 낮은 날은 18일이었고 차이는 두 검정 모두에서 통계적으로 유의하지 않았다($p = 0.185$ 과 $p = 0.164$). 5% 수준에서 두 검정은 표 3의 모든 행에서 같은 판정을 준다. 다만 민감도는 같지 않다. 일곱 행 중 여섯 행에서 부호순위 p 가 더 작는데, 이는 비용이 큰 소수의 날에 효과가 몰려 있는 경우와 부합한다. 이 결과는 시공간 재배치 구조의 효과와 학습 자체의 추가 효과를 구분해 해석해야 함을 보여 준다. 학습 정책이 더 비싼 날은 이틀뿐이었고 차이도 작았다. 가장 큰 감소는 모두 혼잡한 날에서 나타났다(그림 5).




그림 5: 재배치 없음 대비 날짜별 짝비교. 같은 28일에 같은 난수열을 썼고 차이 크기로 날을 정렬했다. 양수는 학습 정책이 더 싼다는 뜻이다. (a)는 28일 전부이며, 혼잡한 나흘이 축을 지배하므로 (b)에서 음영 구간인 1~24위를 확대했다. 학습 정책은 28일 중 26일에서 더 싼다 (양측 부호검정 $p < 0.001$). 더 비쌌던 이들은 -1,708만원과 -51만원으로 작은 반면, 혼잡한 나흘은 각각 2억 9,000만원을 넘었다. 세로축 단위는 백만원이다.

5.4 수요수준과 행동의 분해

표 4는 비용 감소를 수요수준별로 분해한다. 전체 감소의 90.5%가 수요 12,500대와 15,000대인 나흘에서 발생했다. 이는 상시 개입보다 혼잡이 관측될 때 선택적으로 개입하는 정책으로 아키텍처를 발전시킬 근거가 된다. 같은 28일에서 행동을 한 종류씩만 허용하면 공간과 시간 행동의 기여를 구분할 수 있다. 도착시각 조정은 전체 감소의 91.3%를 설명하며, 대부분의 감소가 혼잡한 나흘에서 나왔다(그림 6). 이 비중은 4.5절의 비용 구조와 함께 읽어야 한다. 본 환경에서는 트럭 대기가 총비용의 96.4%를 차지하므로, 대기시간을 줄이는 행동이 지배적인 항에 직접 작용한다. 비용 구성이 다르면 공간 행동과 시간 행동의 우열도 달라질 수 있다. 블록 재배치만 허용한 정책은 원활·보통 수요에서 1.24억원을 줄였지만, 가장 높은 수요에서 비용을 늘렸다. 전체로는 1.31억원 증가했다. 따라서 정책은 수요수준에 따라 공간 행동과 시간 행동의 비중을 조절할 필요가 있다. 이 진단 실행에서는 시간대별 예약 정원을 개방형으로 두었다. 따라서 도착시각 관련 결과는 시간 이동이 제공할 수 있는 가능성의 범위다. 유한한 정원을 적용한 민감도 분석이 실제 적용 범위를 더 분명하게 할 수 있다.

표 4: 수요수준별 비용 감소(재배치 없음 대비, 억원). 셋째부터 다섯째 열은 허용한 행동을 구분한다. 마지막 열은 학습된 모형과 학습 전 모형의 차이다. 도착시간 조정과 학습의 기여는 혼잡한 나홀에 집중됐고, 블록 재배치는 최고 수요에서 비용을 늘렸다.

일일 수요	일일 날 수	두 행동 모두	시간 만	블록 만	학습의 몫
3,500	12	0.47	-0.13	0.57	0.56
5,000	8	0.60	0.29	0.67	0.29
7,500	4	0.32	0.08	0.00	-0.49
12,500	2	6.11	5.73	-0.14	1.44
15,000	2	7.22	7.47	-2.41	4.95
합계	28	14.71	13.44	-1.31	6.75
전체 중 비중		100%	91.3%	—	45.9%




그림 6: 수요수준별 비용 감소를 행동 범위로 분해했다. 값은 표 4에 적은 것과 같고 단위는 백만원이다(억원 값의 100배). 혼잡한 두 다섯 수요 수준을 하나의 축에 함께 그렸고, 음영은 혼잡한 두 수준을 가리킨다. 그 둘이 나머지보다 열 배 넘게 크므로 짧은 막대에는 값을 함께 적었다. 눈금 아래 n 은 관측 일수다. 막대는 행동을 제한한 정책을 재배치 없음과 견준 값이다. 마름모는 넷째 행동이 *아니다* — 학습된 모형에서 학습 전 모형을 뺀 **학습의 몫**, 곧 표 4의 마지막 열이며 그래서 기호를 달리 그렸다. 비혼잡에서 혼잡으로 넘어가면 도착시간 조정과 학습의 몫이 함께 급격히 커지는 반면, 블록만 쓰는 재배치는 음수로 돌아선다.

5.5 같은 행동 범위를 쓰는 규칙 정책

§5.4의 차이가 행동 자체에서 나온 것인지 확인하려면 규칙 정책에도 같은 행동을 허용해야 한다. 이를 위해 공간 축의 *가장 한산한* 곳 기준을 시간 축에 적용한 규칙 두 개를 추가했다. 새 매개변수는 도입하지 않았고, 다른 규칙과 같은 혼잡 조건을

사용했다. 결과는 세 가지로 정리된다. 첫째, 규칙만 사용해도 도착시간 조정은 재배치 없음보다 비용을 3.41% 낮췄다($p = 0.0125$). 따라서 시간 행동 자체에 가치가 있다. 둘째, 시공간 행동 범위를 맞춘 뒤에도 학습 정책이 규칙보다 28일 중 20일에서 낮았다($p = 0.036$). 셋째, 시간 행동만 비교하면 규칙이 더 많은 날에서 낮았다. 학습 정책이 낮은 날은 8일뿐이었지만 총 감소액은 약 4배 컸다. 원활한 수요에서는 규칙이 근소하게 낮았고, 혼잡한 날에는 학습 정책의 감소가 3.8~5.6배 컸기 때문이다. 즉 학습된 정책은 자주 이기기보다 비싼 날의 비용을 크게 줄이는 방향을 보였다. 따라서 승리한 날의 수와 총 감소액을 함께 보고해야 한다. 두 행동을 모두 쓰는 규칙도 혼잡 수요에서 약해졌다. 이는 블록 재배치의 혼잡 민감도가 특정 정책보다 행동 자체와 관련될 수 있음을 시사한다.

5.6 학습 효과와 작업순서 민감도

먼저 모형의 적합도를 확인했다. 30회차 동안 제안망의 Huber 손실은 학습 결정에서 0.079에서 0.029로, 검증 결정에서 0.268에서 0.119로 감소했다. 수락망은 각각 0.171에서 0.027, 0.315에서 0.136으로 감소했다. 값은 처음 다섯 회차와 마지막 다섯 회차의 평균이며 목표 단위는 10만원이다. 검증 손실도 함께 감소했으므로 학습 결과가 처음 보는 결정에도 이어졌다. 다만 마지막 검증 손실은 학습 손실의 약 네 배였다. 회차당 라벨이 약 56개라는 점을 고려하면 모형을 작게 유지할 필요가 있다. 반사실 비용 차이가 정확히 0인 결정의 비율은 탐색이 감소하면서 51.4%에서 37.6%로 줄었다. 전체 학습에서는 4,671개의 반사실 세계를 실행했다. 그림 7은 두 손실 곡선과 함께 그 결을 지키는 탐색 일정을 보여 준다.




그림 7: 30회차 동안의 학습·검증 손실. 회차별 원값을 열게 깔고 그 위에 다섯 회차 이동평균을 얹었다. (a) 제안망과 (b) 수락망은 서로 다른 결정으로 적합하므로 따로 그렸고, 손실이 세 자릿수를 오가므로 세로축은 로그다. (c) 탐색 확률 ϵ 은 0.50에서 0.05로 선형 감소한다. 음영은 그 회차에 뽑힌 수요가 하루 12,500대 이상이었음을 뜻한다. 수요를 회차마다 새로 뽑기 때문에 17~24회차의 상승을 포함해 눈에 보이는 출렁임의 상당 부분은 적합이 아니라 그 추첨을 따른다.

재배치 없음의 비용은 100.0억원이었다. 학습 전 모형은 92.0억원, 학습된 모형은 85.2억원이었다. 따라서 학습 후 추가 감소는 6.75억원이며 전체 감소의 45.9%다. 그러나 학습된 모형이 더 낮은 날은 28일 중 18일에 그쳤다(부호검정 $p = 0.185$, 부호순위 $p = 0.164$). 날짜별 차이의 평균은 -2,410만원으로 중앙값 -130만원의 약 18배다. 이는 학습 효과가 한 달에 고르게 분포하지 않았음을 뜻한다. 표 4의 마지막 열에서 혼잡한 나흘은 학습 효과의 94.6%를 차지했다. 이 나흘에서는 학습된 모형이 모두 낮았다. 더 낮은 수요에서는 각각 9/12, 5/8과 0/4였다. 나머지 24일의 평균 차이는 -150만원이고 부트스트랩 구간은 0을 포함했다. 수요수준(층) 안에서만 날짜별 차이를 다시 뽑는 층화 부트스트랩을 20,000회 수행하면 평균 차이의 95% 백분위 구간은 하루 [-3,200, -1,700]만원이다. 층화는 설계에서 고정한 수요 구성을 대표본이 호트러뜨리지 않게 한다. 층을 나누지 않으면 구간은 [-5,200, -300]만원으로 넓어지며, 대표본의 99.3%가 음수다. 두 구간 모두 0을 제외하지만 혼잡 수준마다 날짜가 이틀뿐이므로 층화 구간은 설계상 좁아진 측면이 있다. 따라서

해석에는 주의가 필요하다. 학습은 총액을 크게 줄였고 혼잡한 나흘에서는 모두 낮았지만, 날짜 단위 부호검정에서는 유의하지 않았다. 통상적인 유의수준에서 학습 효과를 확정하려면 단순히 전체 날짜를 늘리기보다 혼잡한 날짜를 더 많이 관측해야 한다. 크레인 작업순서 규칙의 상대 순위도 수요에 따라 바뀌었다. 현행 최단 처리시간 규칙은 원활·보통 수요에서 다른 규칙보다 22-25% 비쌌지만, 수요 7,500대 이상에서는 가장 낮았다. 설계된 수요 비중으로 가중한 전체 비용도 가장 낮았다. 따라서 재배치 정책의 효과가 다른 작업순서 규칙에서도 유지되는지 확인할 필요가 있다.

6 결론

본 연구는 이미 통지된 외부 트럭 작업의 야드 블록과 도착시각을 운영 중에 함께 재검토하는 강화학습 아키텍처를 제안했다. 이 구조는 분산 예약 협상 [3]과 야드 크레인 운영 [4, 5]을 하나의 시공간 배치 문제로 연결한다. 재배치의 영향은 뒤따르는 트럭, 크레인과 선박 작업에서 나중에 나타난다. 따라서 각 정책은 즉시 이동비보다 고정 지평에서 측정한 반사실 비용 차이를 학습한다. 이는 다중 행위자 반사실 학습 [9, 10]을 운영 의사결정에 적용하는 방법이다. 계산량이 큰 반사실 분기는 오프라인 학습에만 사용하므로, 운영 경로에는 작은 비용모형과 제약 검사만 남는다.

efsec:env질의 합성환경에서 제안 구조는 관측부터 제안, 수락, 확정과 실행까지 시공간 재배치의 전체 경로를 수행했다. 비용 감소는 주로 혼잡 조건의 도착시각 조정에서 나타났다. 즉 실시간 혼잡 정보가 모니터링에 그치지 않고 배치 행동으로 이어졌다. 같은 행동 범위를 가진 규칙과 비교해도 총비용은 학습 정책이 더 낮았다. 다만 시간 행동만 비교하면 규칙이 더 많은 날에서 낮았고, 학습 정책은 혼잡한 날의 큰 감소로 총액에서 앞섰다. 따라서 결과는 승리한 날짜 수와 총 감소액을 함께 보아야 한다.

6.1 한계

결과의 해석에는 여덟 가지 한계가 있다. 첫째, 환경은 합성이다. 규모와 변동은 문헌의 범위에 맞췄지만 특정 터미널의 운영기록에 적합하지 않았다. 수요 구성, 도착곡선 계수와 네 비용 계수 중 둘도 설계값이다. 둘째, 학습과 평가는 같은 도착곡선 형태를 사용하고 수요 수준과 난수만 다르다. 따라서 처음 보는 도착 형태에 대한 일반화는 확인하지 못했다. 셋째, 혼잡한 날은 28일 중 나흘뿐이었고 비용 감소도 이 나흘에 집중됐다. 학습 효과를 확정하려면 전체 날짜보다 혼잡한 날짜를 더 많이 평가해야 한다. 넷째, 독립 수락 정책의 기여를 따로 분리하지 않았다. 한쪽만 동의한 작업이 확정되지 않는다는 작동은 확인했지만, 수락 정책의 거부권을 제거했을 때의 비용 변화는 측정하지 않았다. 따라서 제안과 수락의 분리는 현재로서는 작동 확인에 근거한 설계 선택이다. 다섯째, 시간대별 예약 정원을 개방형으로 두었기 때문에 도착시각 결과는 실행 가능한 일정이 아니라 가능성의 상한을 나타낸다. 여섯째, 3시간의 반사실 지평은 보고된 현장값이 아니다. 검토 창 30분, 최대 이연 120분과 도착압력 여유 30분을 합한 설계값이다. 일곱째, 주 비교는 하나의 크레인 작업순서 규칙을 사용한다. 규칙의 순위가 수요에 따라 바뀌므로 다른 규칙 아래에서는 재배치 효과의 크기도 달라질 수 있다. 마지막으로 본 연구의 비용 계수에서는 트럭 대가 총비용의 96.4%를 차지한다. 따라서 도착시각 조정이 블록 재배치보다 우세하다는 결과가 다른 비용 구조에서도 유지되는지는 비용 계수 민감도 분석으로 확인해야

한다. 이 단계는 한 번에 한 축씩 검증할 수 있다. 실제 예약 정원을 반영하면 시간 조정의 실행 가능 범위를 구체화할 수 있다. 다양한 혼잡 조건을 반복하면 학습 전 모형 대비 기여도 더 분명해진다. 본 연구는 관측-제안-수락-확정-실행-반사실 학습을 하나의 재현 가능한 구조로 정리했다. 자동화 장비와 예약정보가 늘어나는 스마트항만에서 이 구조는 실시간 혼잡 정보를 설명 가능한 자원 배치 결정으로 연결하는 기반이 될 수 있다.

사사. 이 논문은 중소벤처기업부의 민관공동 기술개발사업(기술이전 사업화, RS-2026-25529952) 지원을 받아 수행된 연구입니다.

이해관계 공시. 저자들은 이 논문의 내용과 관련하여 공시할 이해관계가 없습니다.

References

1. Yen, B.T.H., et al.: How smart port design influences port efficiency: a DEA-Tobit approach. *Res. Transp. Bus. Manag.* **46**, 100862 (2023)
2. Chen, G., Govindan, K., Yang, Z.: Managing truck arrivals with time windows to alleviate gate congestion at container terminals. *Int. J. Prod. Econ.* **141**(1), 179–188 (2013)
3. Phan, M.-H., Kim, K.H.: Collaborative truck scheduling and appointments for trucking companies and container terminals. *Transp. Res. B* **86**, 37–50 (2016)
4. Ng, W.C., Mak, K.L.: Yard crane scheduling in port container terminals. *Appl. Math. Model.* **29**(3), 263–276 (2005)
5. Speer, U., Fischer, K.: Scheduling of different automated yard crane systems at container terminals. *Transp. Sci.* **51**(1), 305–324 (2017)
6. Petering, M.E.H., Murty, K.G.: Effect of block length and yard crane deployment systems on overall performance at a seaport container transshipment terminal. *Comput. Oper. Res.* **36**(5), 1711–1725 (2009)
7. Schwientek, A., Lange, A.-K., Jahn, C.: Simulation-based analysis of dispatching methods on seaport container terminals. *ARGESIM Report* **59**, 357–364 (2020)
8. Wang, W., et al.: Yard crane real-time scheduling among multi-block at terminal: A reinforcement learning based proximal policy optimization approach. *Transp. Res. E* **207**, 104635 (2026)
9. Wolpert, D.H., Tumer, K.: Optimal payoff functions for members of collectives. *Adv. Complex Syst.* **4**(2–3), 265–279 (2001)
10. Foerster, J., et al.: Counterfactual multi-agent policy gradients. In: *AAAI*, vol. 32 (2018)
11. Kourounioti, I., Polydoropoulou, A.: Application of aggregate container terminal data for the development of time-of-day models predicting truck arrivals. *EJTIR* **18**(1) (2018)
12. Mnih, V., et al.: Human-level control through deep reinforcement learning. *Nature* **518**(7540), 529–533 (2015)
13. Hornik, K.: Approximation capabilities of multilayer feedforward networks. *Neural Netw.* **4**(2), 251–257 (1991)
14. Kim, S., Mowakeaa, R., Kim, S.-J., Lim, H.: Building energy management for demand response using kernel lifelong learning. *IEEE Access* **8**, 82131–82141 (2020)
15. Ministry of Land, Infrastructure and Transport: Notice on Safe Freight Rates for Cargo Vehicles Applicable in 2026. MOLIT Notice No. 2026-402 (2026)

16. Ministry of Oceans and Fisheries: Regulations on the Use of Port Facilities and Fees at Trade Ports, etc. MOF Notice No. 2025-218 (2025)
17. Huber, P.J.: Robust estimation of a location parameter. *Ann. Math. Statist.* **35**(1), 73–101 (1964)
18. Kleijnen, J.P.C.: Analyzing simulation experiments with common random numbers. *Manag. Sci.* **34**(1), 65–74 (1988)