

스마트 컨테이너 터미널의 시공간 재배치를 위한 강화학습 아키텍처: 독립 제안·수락 정책과 반사실 비용 학습

저자명¹

소속 기관, 주소 email@example.com

Abstract. 스마트항만은 자동화 장비와 디지털 정보를 결합해 한정된 공간, 장비와 차량 흐름을 효율적으로 조정하는 방향으로 발전하고 있다. 선행연구는 스마트 기술의 효과가 운영 조건과 적용 방식에 따라 달라지므로, 관측 정보를 실제 자원 배치와 운영 판단으로 연결하는 정책이 중요하다고 설명한다 [1]. 본 연구는 이미 통지된 외부 트럭 작업의 야드 블록과 도착시각을 실시간 혼잡에 따라 함께 재검토하는 강화학습 아키텍처를 제안한다. 재배치를 요청하는 정책과 이를 받을 블록 또는 시간대의 수락 정책을 독립적으로 구성하고, 양쪽이 동의한 후보만 중앙 질차가 자원 제약 아래에서 확정한다. 각 정책은 동일한 상태에서 현재 행동만 바꾼 이산사건 시뮬레이션의 비용 차이를 학습하며, 운영 단계에서는 학습된 신경망만 사용한다. 아키텍처는 선행연구의 터미널 규모, 시간대별 트럭 도착, 복수 야드 크레인과 선박 기항량 범위를 반영한 연속 합성환경에서 평가했다. 학습에 사용하지 않은 난수 조건에서 재배치 없음, 규칙 기반 정책과 학습 전 모형을 함께 비교했다. 그 결과 제안·수락·확정·실행으로 이어지는 의사결정 경로가 연속 운영 중 안정적으로 작동했고, 비용 감소 방향은 혼잡한 조건의 도착시각 조정에서 뚜렷하게 관찰됐다. 행동 범위를 맞춘 규칙 정책과의 비교에서도 학습된 모형이 낮은 비용 방향을 보였다. 본 연구의 기여는 특정 성능값보다 실시간 혼잡 관측, 독립된 제안과 수락, 상호 동의, 반사실 비용 학습, 빠른 운영 추론을 하나의 실행 구조로 제시한 것에 있다.

Keywords: 스마트항만 · 컨테이너 터미널 · 트럭 도착 관리 · 야드 블록 재배치 · 반사실 학습 · 강화학습

1 서론

스마트항만의 운영 효율화는 장비 자동화뿐 아니라 실시간으로 관측한 정보를 바탕으로 자원을 다시 배치하는 능력에 달려 있으며, 항만 효율 연구는 장비와 차량 정보를 운영 시나리오에 연결한다 [1]. 컨테이너 터미널에서 외부 트럭의 작업 블록과 예약시각은 도착 전에 정해지지만, 운영 중에는 특정 시간대나 블록에 수요가 몰리고 크레인 대기가 함께 변한다. 최초 계획을 그대로 유지하면 새로 관측된 혼잡을 반영하기 어렵다. 본 연구는 작업을 어디에 배치할지와 트럭을 언제 도착하게 할지를 함께 재검토한다.

트럭 예약 연구는 시간창으로 도착 피크를 분산하고 터미널과 운송사가 각자의 비용에 따라 도착시각을 협의하게 하며 [2, 3], 야드 운영 연구는 배치·작업순서·크레인 간섭을 다룬다 [4–6]. 두 흐름은 시간과 공간의 효율을 따로 높여 왔고, 본 연구는 두 축을 하나의 실시간 결정 안에 넣는다. 이런 재배치는 한 작업의 비용만

2 저자명

그림 1. 재배치 결정 흐름과 학습·운영의 분리



Fig. 1: 재배치 결정 흐름과 학습·운영의 분리. 운영 경로는 학습된 신경망만 사용하며 반사실 시뮬레이션을 호출하지 않는다.

바꾸지 않는다 — 작업이 옮겨지면 뒤에 오는 트럭의 대기, 크레인 작업순서, 선박 공급 흐름이 함께 달라지므로 뒤따르는 혼잡을 포함한 비용 신호가 필요하고, 차이 보상과 다중 행위자 반사실 기준선이 한 행동을 대안과 비교해 그 신호를 준다 [7, 8]. 재배치는 제안하는 쪽의 이익만으로 확정하기도 어렵다. 목적지가 그 작업을 감당할 수 있는지는 따로 판단해야 하기 때문이다. 그래서 제안과 수락을 나누고 합의와 실행 가능성은 중앙 절차에 맡긴다.

본 연구는 독립된 제안·수락 정책으로 시공간 재배치를 구성할 수 있는지, 반사실 학습을 운영 추론과 분리할 수 있는지, 이 아키텍처가 운영비를 줄이는지, 그리고 관찰된 변화에서 학습의 몫과 행동 범위의 몫을 갈라낼 수 있는지를 묻는다. 기여는 독립 정책 구조, 시공간 행동 범위, 반사실 비용 학습, 학습·운영 분리, 그리고 실행·행동 범위·학습 효과를 나누어 보고하는 분해 가능한 평가다.

2 관련 연구

스마트항만 연구는 자동화, 지능화와 환경 설계를 항만 효율의 서로 다른 구성요소로 본다 [1]. 시간창 예약은 집중된 트럭 도착을 분산하고 [2], 협상 연구는 운송사와 터미널이 제한된 정보를 교환하며 도착시각을 조정할 수 있음을 보였으며 [3], 도착은 하루 중 균일하지 않다 [9]. 공간 쪽에서는 야드 크레인 연구가 작업순서·간섭·부하 배분을 다루고 [4, 5], 이산사건 시뮬레이션이 블록 길이와 크레인 배치의 장기영향을 비교하며 [6], 배차 규칙의 순위가 터미널 조건에 따라 뒤집힌다 [10]. 항만 강화학습은 실시간 크레인 배차까지 왔으나 [11], 본 연구는 그 상위 계층을 다룬다.

한 행동의 효과를 공동 비용에서 분리하는 차이 보상은 다른 행위자의 행동을 유지한 기준선과 현재 결과를 비교하며 [7], 다중 행위자 반사실 정책경사는 중앙 가치모형으로 그 기준선을 구성한다 [8]. 본 연구는 이를 이산사건 시뮬레이션에 적용해, 한 행동만 바꾼 두 실행의 원화 비용 차이를 독립 정책의 회귀 목표로 삼는다. 환경 불확실성 아래에서 자원 단위 제어를 기계학습으로 다루는 인접 사례로 건물 수요반응 연구가 있다 [12]. 그 연구도 실측 환경 기록과 개별 단위의 변동을 만드는 합성 매개변수를 함께 쓰고 합성 부분을 선언적으로 적는데, 본 연구가 3.1절에서 따르는 방식과 같다. 정책 비교에서는 같은 난수를 공유하는 짝비교를 사용한다 — 공통 난수는 정책 차이의 잡음을 줄이는 전통적인 방법이다 [13].

본 연구의 차별점은 도착시각 조정과 블록 재배치를 함께 다루는 행동 범위, 독립된 제안·수락 정책, 상호 동의 기반 확정, 반사실 비용 학습과 운영 추론의 분리를 하나의 아키텍처로 구성한 데 있다.

3 실험환경

3.1 문헌 기반 합성환경

제안한 아키텍처의 성능은 수치 실험으로 확인한다. 실험을 되도록 현실에 가까운 조건에서 수행하기 위해 기존 컨테이너 터미널 연구가 보고한 규모와 운영 범위를 가능한 범위에서 사용했다. 따라서 실험 대상은 특정 터미널의 운영자료를 복제한 환경이 아니라 *문헌 기반 합성환경*이다. 선행연구는 20블록 [10], 블록별 복수 크레인 [5], 여러 주에 걸친 연속 모의 [6], 시간대별 도착확률 [9], 기항량이 다른 세 선박 등급 [10], 크레인 취급시간의 삼각분포 범위 [6]를 보고한다. 본 연구는 그 범위 안에서 21블록, 블록당 크레인 2기, 상태를 이어 가는 30일, 균등 바닥에 봉우리 셋을 더한 도착곡선, 세 선박 등급, 크레인 서비스시간 180초로 고정했다. 이 고정값들은 연구의 설계 선택이다. 인용은 그 값이 기존 연구의 모형 범위 안에 놓인다는 근거이며, 특정 항만의 운영자료에서 왔다는 뜻이 아니다.

3.2 터미널과 시간 설정

야드는 21블록이고 블록마다 야드 크레인 2기를 두어 모두 42기다. 블록 용량은 1,440 슬롯이며 시작 점유율은 65%다. 게이트와 안벽은 반대쪽에 있는 1차원 배치이고, 결정 간격은 60초다. 운영은 30일 연속이며 가운데 28일을 비교한다. 크레인 작업순서는 실제 작업을 우선하고 그 안에서 예상 처리시간이 짧은 작업을 먼저 수행한다. 하루는 터미널이 자정에 멈춘다는 뜻이 아니라 비용을 나누는 절단면이다. 야드 재고, 대기열, 크레인 상태와 미완료 작업은 다음 날로 이어지며, 첫날과 마지막날이 그 경계를 잇는다.

3.3 외부 트럭 수요와 도착 과정

d 일의 일일 수요는 $\{3,500, 5,000, 7,500, 12,500, 15,000\}$ 대 위의 이산분포에서 확률 $\{0.30, 0.30, 0.25, 0.10, 0.05\}$ 로 뽑았다. 앞의 셋은 원할·보통·높은 수요이고 뒤의 둘은 혼잡·초혼잡 조건이다. 하루 안에서 각 작업의 통지 시각은 시간대별 도착밀도 $f(t)$ 에서 뽑았으며, 이는 균등 바닥과 정규분포 봉우리 셋의 혼합으로 (μ_m, σ_m, w_m) 은 각각 $(10, 1.5, .317)$, $(15, 2.5, .633)$, $(21, 1, .05)$ 이다.

$$f(t) = 0.38 U(0, 24) + 0.62 \sum_{m=1}^3 w_m \mathcal{N}_{[0,24]}(t; \mu_m, \sigma_m^2). \quad (1)$$

시간 단위는 시(hour)이고 절단된 밀도는 하루 합이 1이 되도록 다시 정규화한다. 도착 모형은 [9]을 따르며, 혼합비와 중심시각은 수요수준별 혼잡 민감도를 비교할 수 있도록 정한 설계값이지 특정 터미널에 적합시킨 추정값이 아니다. 균등 바닥이 야간에도 도착을 0으로 두지 않으므로, 날 경계를 넘어 이어지는 야드 상태가 빈 밤의 산물이 아니라는 점에 유의한다.

3.4 선박과 안벽 작업

선박은 세 등급으로 나뉘었다 — 소형(50,000 GT · 3,000 TEU · STS 2기 · 시간당 유틸비용 149,500원), 중형(100,000 GT · 7,500 TEU · 4기 · 299,000원), 대형

(150,000 GT · 14,000 TEU · 6기 · 448,500원). 용량 C TEU 인 선박의 기항 작업량은 $u \sim U[0.15, 0.30]$ 에 대해 $C \cdot u$ 로 뽑았고, 하루 구성은 소형 2척과 중형 1척이며 대형 1척을 30% 확률로 더했다. STS 1기의 처리율은 27.5 move/h로 두며 이는 문헌의 24·30·36 move/h 범위 안에 있다 [10]. 여러 STS의 막힘은 합산한 뒤 배정 대수로 나누어 선박 단위 유휴시간으로 환산한다. 야드 쪽에서 크레인 1기의 기준 서비스 시간은 180초/move이므로 이론상 총 이동능력은 $\mu_{YC} = 21 \times 2 \times 3600/180 = 840$ move/h다. move/h는 컨테이너 이동 횟수이며 트럭 건수와 다르다. 트럭 한 건은 이동과 재취급을 여러 번 요구할 수 있고 실제 서비스시간도 위치와 작업 종류에 따라 변하므로, 이동 단위와 트럭 단위를 구분해 보고한다.

3.5 비용함수

날짜 구간 $[d, d+1]$ 의 총비용은 네 항의 합으로 정의한다.

$$\Phi_d = C_{wait,d} + C_{move,d} + C_{rehandle,d} + C_{vessel,d}. \quad (2)$$

트럭 체류는 시간당 40,000원이며 1시간 초과분에 같은 단가를 더한다. 안전운임을 화폐 기준점으로 사용하고 시간 환산은 연구값이다 [14]. 추가 크레인 이동은 작업시간당 60,000원, 재취급은 회당 2,000원으로 두며 둘 다 연구 설계값이다. 선박 유휴는 GT·시간당 2.99원으로, 접안 초과요금 29.9원/10GT·시간을 환산했다 [15]. 트럭 i 의 체류시간을 h_i , 추가 크레인 작업시간을 m , 재취급 횟수를 R , 선박 v 의 정책 관련 유휴시간을 T_v 라 하면 다음과 같다.

$$C_{wait} = \sum_i 40,000 \{h_i + \max(0, h_i - 1)\}, C_{move} = 60,000 m, C_{rehandle} = 2,000 R, C_{vessel} = \sum_v 2.99 GT_v T_v. \quad (3)$$

접이안과 검역처럼 재배치 정책이 바뀌지 않는 구조적 선박 시간은 진단값으로 분리한다. 네 비용 항은 같은 날짜 경계의 누적값 차이로 계산한다.

이렇게 정한 환경의 성질 두 가지를 학습 30일 실행에서 측정했다. 첫째, 비용은 대기가 지배한다. C_{wait} 가 총비용의 96.4% 이고 재취급 2.2%, 선박 유휴 1.2%, 추가 크레인 이동 0.1% 다. 따라서 Φ 로 내린 판단은 규정에서 가져온 안전운임 계수 [14]가 사실상 좌우하며, 문헌값이 아니라 설계값인 나머지 두 계수에는 둔감하다. 둘째, 대기의 비중과 서비스 수준이 수요와 함께 급격히 나빠진다. 대기는 하루 3,500대에서 비용의 83.2%, 7,500대에서 91.7%, 15,000대에서 99.1%로 올라가며 다른 항을 모두 밀어낸다. 한 달 전체로는 평균 체류시간 0.89시간, 90분위 2.01시간이고 트럭 작업 206,904건 중 5.0%가 통지된 날 안에 끝나지 않았다. 그런데 그 90분위는 가장 한산한 날 0.79시간에서 가장 붐비는 날 7.49시간까지 9.5배로 벌어진다. 즉 혼잡한 날은 단지 더 비싼 것이 아니라 비싼 이유가 다르며, 재배치 정책이 이용하도록 요구받는 성질이 바로 이것이다.

4 정책과 학습

4.1 기호와 결정 단위

결정 간격을 $\delta = 60$ 초, 야드 블록 집합을 $\mathcal{B}$, 도착시각 이연 후보를 $\mathcal{D}$ 라 한다. 작업 i 의 현재 배정은 $z_i = (b_i, \tau_i)$ 이며 b_i 는 블록, τ_i 는 통지된 도착예정시각이다. 재배치 행동은 다음과 같다.

$$a_i = (b'_i, \Delta_i) \in \mathcal{A}_i(t), \quad z_i(a_i) = (b'_i, \tau_i + \Delta_i). \quad (4)$$

원배정 유지는 $a_i^0 = (b_i, 0)$, 블록 재배치는 $b'_i \neq b_i$, 도착시각 조정은 $\Delta_i > 0$ 이다. 두 값이 함께 바뀌는 후보도 허용한다. 반출 작업은 꺼낼 컨테이너 위치가 정해져 있으므로 블록 재배치 후보에서 제외한다.

작업의 통지시각을 n_i , 게이트 진입시각을 g_i , 최초 검토 여부를 r_i 라 하면 시점 t 에 새로 검토하는 집합은 다음과 같다.

$$\mathcal{E}_t = \{i \mid n_i \leq t < n_i + \delta, g_i > t, r_i = 0\}. \quad (5)$$

즉 아직 도착하지 않은 작업을 통지가 자격 창에 처음 들어온 한 시점에서만 검토한다.

4.2 독립된 제안 정책과 수락 정책

제안 정책은 자기 블록 상태와 작업·행동 특징 o_i^P 를 이용해 예상 비용이 가장 낮은 행동을 고른다.

$$\hat{a}_i = \arg \min_{a \in \mathcal{A}_i(t)} \hat{c}_\theta^P(o_i^P, a), \quad p_i = \mathbf{1}[\hat{a}_i \neq a_i^0]. \quad (6)$$

제안이 있으면 목적 블록 또는 목표 시간대가 수락 주체가 된다. 수락 정책은 제안 메시지와 자기 상태 o_i^A 를 보고 수락과 거절의 예상 비용을 비교한다.

$$q_i = \mathbf{1}[\hat{c}_\psi^A(o_i^A, \hat{a}_i, \text{accept}) \leq \hat{c}_\psi^A(o_i^A, \hat{a}_i, \text{reject})]. \quad (7)$$

목표 자원의 남은 용량이 0이면 신경망 판단 전에 거절한다. 두 정책이 함께 동의한 후보 집합은 $\mathcal{J}_t = \{i \in \mathcal{E}_t \mid p_i q_i = 1\}$ 이다. 독립된 두 주체가 제한된 정보를 바탕으로 도착시각을 협의하는 문제 구조는 [3]을 참고했다.

4.3 중앙 확정 제약

중앙 절차는 새 후보를 만들지 않고 $\mathcal{J}_t$ 안에서만 확정한다. 동의 후보를 수락 정책의 예측비용 오름차순으로 정렬하고 동점은 작업·좌표의 사전순으로 처리한다. 후보 i 의 확정 여부를 $x_i \in \{0, 1\}$, 목적 블록의 남은 슬롯을 $F_b(t)$, 예약 시간대 k 의 남은 정원을 $K_k(t)$ 라 하면 다음 제약을 만족한다.

$$x_i \leq p_i q_i, \quad \sum_{i \in \mathcal{J}_t} x_i \mathbf{1}[b'_i = b] \leq F_b(t), \quad \sum_{i \in \mathcal{J}_t} x_i \mathbf{1}[k(i) = k] \leq K_k(t), \quad \sum_{t \in \mathcal{T}} \mathbf{1}[i \in \mathcal{E}_t] \leq 1. \quad (8)$$

현행 실험에서 블록 용량 제약은 활성화돼 있다. 시간대 정원 자료가 없는 조건은 $K_k(t) = \infty$ 로 두며, 이 조건의 효과는 시간 조정 가능성의 범위로 해석한다. 확정된 새 배정은 모두 같은 시점에 일괄 반영하므로, 먼저 확정된 작업이 같은 결정 시점의 뒤 후보가 보는 상태를 바꾸지 않는다. 따라서 두 조건이 구성으로 성립한다 — 제안과 수락을 모두 지닌 후보만 확정되고, 한 작업은 정확히 한 번만 검토된다.

4.4 정책모형과 입력

두 정책은 고정 길이 특징을 후보별로 평가하는 다층퍼셉트론이며 모든 블록이 같은 가중치 한 벌을 공유한다. 제안 정책의 입력은 21차원, 수락 정책은 16차원이고 은닉층은 둘 다 64-ReLU-64-ReLU이며, 매개변수는 각각 5,633개와 5,313개로 합쳐 11,000개가 안 된다. 입력은 현재 대기·재고·크레인 잔여, 공개 도착예정시간, 경로 차이와 목표 시각 주변의 통지 물량으로 구성한다. 아직 실현되지 않은 실제 도착·완료 시각과 다른 수락 주체의 동시 응답은 입력에서 제외한다.

4.5 반사실 비용 라벨

표본 결정마다 분기 직전 상태와 난수를 복제하고 최대 세 세계를 3시간 실행한다.

$$\phi_i^F = \Phi_H(\text{관측 행동}), \quad \phi_i^P = \Phi_H(\text{제안만 반대}), \quad \phi_i^A = \Phi_H(\text{수락만 반대}), \quad H = 10,800 \text{ s.} \quad (9)$$

수락 제안이 없는 결정은 제안 비교만 만든다. 각 정책의 두 행동은 같은 평균을 빼고 100,000원으로 나누어 학습한다.

$$\bar{\phi}_i^P = \frac{\phi_i^F + \phi_i^P}{2}, \quad y_{i,F}^P = \frac{\phi_i^F - \bar{\phi}_i^P}{100,000}, \quad y_{i,P}^P = \frac{\phi_i^P - \bar{\phi}_i^P}{100,000}. \quad (10)$$

수락 정책도 (ϕ_i^F, ϕ_i^A) 에 같은 중심화를 적용한다. 평균 차감은 두 행동의 순서를 바꾸지 않으면서 공통 비용을 제거한다. 한 행위만 바꾼 기준선은 차이 보상과 다중 행위자 반사실 기준선 연구에 닿아 있다 [7, 8].

4.6 학습 설정과 운영 분리

학습일당 표본 상한은 64개 결정이고 탐색 확률은 0.50에서 0.05까지 선형으로 줄인다. 학습과 검증은 결정 단위로 80%와 20%로 나눈다. 최적화는 Adam(학습률 3×10^{-4}), 손실은 Huber($\beta = 1.0$), 미니배치는 최대 256행이며 갱신 횟수는 $\max(50, \min(600, 4 \times \text{학습행 수}))$ 다. 기울기는 1.0으로 제한한다.

반사실 분기는 CPU 여러 코어에서 병렬 실행하고 그날 생성한 라벨은 당일 갱신 뒤 교체한다. 운영 평가에서는 가중치를 고정하고 탐색을 끄며 반사실 분기를 호출하지 않는다.

두 망의 학습에 24회차 동안 CPU 시간 4.7시간가 들었다. 운영 시각의 결정은 후보 하나당 위 크기의 망을 한 번 통과시키는 비용이라 함께 수행하는 제약 검사에 비해 무시할 수 있다. 이 방법의 비용은 전적으로 반사실 라벨 생성에 있으며, 그 작업은 오프라인에서 이루어져 운영 경로에 들어오지 않는다.

5 실험결과

5.1 결과의 범위

아래 결과는 학습과 겹치지 않는 난수시드 9,900,950으로 만든 30일 연속 진단 실행의 가운데 28일이다. 가중치를 고정하고 탐색확률을 0으로 두었으며, 같은 날짜의

Table 1: 같은 28일 위의 모든 정책을 비용 감소율 순으로 정렬했다. 오른쪽 두 열은 각 정책을 제안 정책과 날짜별로 견준 결과다. 사용 행동 열을 따라 내려 읽으면 규칙이 보인다 — 도착시각을 쓰는 정책은 모두 비용을 낮추고, 블록 재배치만 쓰는 정책은 모두 0 근처에 머문다.

정책	사용 행동	제안 정책 대비		
		감소율	낮은 날	p
제안 정책	블록 + 시각	+14.72%	—	—
제안 정책 (시각만)	시각	+13.44%	—	—
학습 전 모형	블록 + 시각	+7.97%	18/28	0.185
규칙: 한산한 시간대	시각	+3.41%	—	—
규칙: 한산한 블록 + 시간대	블록 + 시각	+1.51%	20/28	0.036
규칙: 최소 여유시간	블록	+0.53%	20/28	0.036
규칙: 선착순	블록	+0.17%	22/28	0.004
규칙: 최단 처리시간	블록	+0.05%	21/28	0.013
규칙: 순이득	블록	-0.48%	21/28	0.013
제안 정책 (블록만)	블록	-1.31%	—	—
재배치 없음	—	0.00%	26/28	<0.001

모든 정책은 같은 트럭·선박·서비스 난수를 공유했다. 날짜마다 네 비용 항, 수요 수준, 거래 유형, 미완료 작업, 장기 대기를 저장한다. 소스코드와 정책별 원자료, 모든 그림을 만드는 스크립트를 논문과 함께 공개하므로 난수시드·체크포인트·명령을 그대로 재현할 수 있다.

5.2 아키텍처 작동 확인

구조적 작동은 여섯 조건으로 확인했고 확인 경로는 조건마다 다르다. 제안과 수락을 서로 다른 모형이 판단하는 것, 한쪽 동의만으로 확정된 재배치가 0건인 것, 미래의 실제 도착·완료시각이 정책 입력에 들어가지 않는 것, 날짜 경계에서 상태가 초기화되지 않는 것은 구현과 확정 제약, 그리고 자동 시험에서 따라 나온다. 두 조건은 실행 자체에서 확인됐다 — 고정정책 평가 중 반사실 시뮬레이션 호출이 0회였고, 행동을 바꾸지 않은 분기가 본 실행의 행동과 비용을 재현하는 동일성 검사가 반사실 라벨이 존재하는 학습 실행에서 4/4 통과했다.

5.3 정책별 날짜 짝비교

비용 차이는 제안 정책에서 비교 정책을 뺀 값이며, 음수이면 제안 정책의 비용이 더 낮다. 날짜를 독립 비교 단위로 두고 양측 부호검정을 사용했다(표 1). 같은 짝에 대해 부호뿐 아니라 날짜별 차이의 크기까지 함께 쓰는 월콕슨 부호순위검정을 적용해도 결론은 어디서도 달라지지 않으며 오히려 약해지지도 않는다(모든 규칙 정책에 대해 $p \leq 0.017$).

28일 총비용은 재배치 없음이 100.0억원, 제안 정책이 85.2억원으로 14.71억원 (14.7%) 감소했다. 정책별 감소율은 표 1에 있다. 위 규칙 네 정책은 블록 재배치만 사용하므로 이 비교는 아키텍처 전체의 가능성을 나타내며, 행동 범위를 맞춘 비

Table 2: 감소가 어디서 나오는가 — 수요수준별, 재배치 없음 대비(억원). 셋째에서 다섯째 열은 한 번에 한 행동만 허용한 조건이고, 마지막 열은 그 감소 중 학습이 보태는 몫으로 학습된 모형을 학습 전 모형과 견준 값이다. 도착시각 조정이 감소의 거의 전부를 만들며 그것도 혼잡한 나홀에서 나오고, 블록 재배치는 수요가 가벼울 때 도움이 되다가 가장 높을 때 손해로 돌아서며, 학습의 몫도 같은 혼잡일 양상을 따른다.

일일 수요	일 날 수	두 행동 모두	시각 만	블록 만	학습의 몫
3,500	12	0.47	-0.13	0.57	0.56
5,000	8	0.60	0.29	0.67	0.29
7,500	4	0.32	0.08	0.00	-0.49
12,500	2	6.11	5.73	-0.14	1.44
15,000	2	7.22	7.47	-2.41	4.95
합계	28	14.71	13.44	-1.31	6.75
전체 중 비중		100%	91.4%	—	45.9%

교는 §5.5에서 따로 다룬다. 제안 정책의 비용이 더 큰 날은 수가 적고 차이도 작은 반면, 가장 크게 줄인 날은 모두 수요가 혼잡한 날이다.

5.4 수요수준과 행동의 분해

표 2가 감소를 수요수준별로 분해한다. 전체의 90.5%가 수요 12,500대와 15,000대인 나홀에서 나왔고, 이는 제안 아키텍처를 상시 개입보다 혼잡이 관측될 때 선택적으로 개입하는 정책으로 발전시킬 근거가 된다. 같은 28일에서 한 번에 한 행동만 허용하면 두 기여가 갈라진다 — 도착시각 조정이 전체 감소의 91.4%를 설명하고 그 대부분이 그 나홀에서 나오는 반면, 블록만 허용한 조건은 원활·보통 수요에서 1.24억원을 줄이지만 가장 높은 수요에서 비용을 올려 합계로는 1.31억원 증가한다. 따라서 정책은 수요수준에 따라 공간 행동과 시간 행동의 사용 비중을 조절하는 방향으로 최적화될 수 있다. 이 진단 실행에서 시간대별 예약 정원은 개방형이었으므로 도착시각 관련 수치는 시간 이동이 제공할 수 있는 가능성 범위이며, 유한 정원을 넣은 민감도 분석으로 적용 범위를 정교화할 수 있다.

5.5 같은 행동 범위를 쓰는 규칙 정책

§5.4는 규칙에 같은 행동을 주면 어떻게 되는가라는 물음을 남긴다. 공간 축에서 쓰던 가장 한산한 곳 기준을 시간 축으로 옮겨 규칙 둘을 추가했다. 새 파라미터를 도입하지 않고 기준이 적용되는 축만 바꾼 것이며, 다른 규칙과 같은 혼잡 조건을 공유한다. 표 1가 이들을 다른 정책들 사이에 놓는다. 세 가지가 따라 나온다. 규칙 만으로도 도착시각 조정은 비용을 유의하게 낮추므로(재배치 없음 대비 +3.41%, $p = 0.0125$) 그 행동 자체가 값을 가진다. 행동 범위를 맞추어도 제안 정책이 규칙 보다 여전히 싸다(20/28, $p = 0.036$). 그런데 도착시각 축만 놓고 보면 규칙이 더 많은 날에 낮았다(제안 정책 8/28). 총액은 제안 정책이 약 4배 낮았는데, 원활한 수요에서는 규칙이 근소하게 낮고 혼잡한 날에는 제안 정책이 3.8–5.6배 낮기 때문이다. 학습된 선택은 자주 이기는 방향이 아니라 비싼 날에 크게 줄이는 방향으로 최적화됐으며, 두 지표를 함께 보고해야 이 성질이 드러난다. 두 행동을 모두 쓰는

규칙도 혼잡 수요에서 약해져 §5.4에서 관찰한 성질 — 블록 재배치가 혼잡에서 비용을 올린다는 것 — 을 그대로 재현하며, 이는 그 성질이 특정 정책이 아니라 행동 자체에 속함을 시사한다.

5.6 학습 효과와 작업순서 민감도

재배치 없음 100.0억원에서 학습 전 모형은 92.0억원, 학습된 모형은 85.2억원이었다. 학습 뒤 추가 감소는 6.75억원으로 전체 감소의 45.9%다. 그런데 날짜를 세면 학습된 모형이 28일 중 18일만 낮았고($p = 0.1849$), 날짜별 차이의 평균(-2,410만원)은 중앙값(-130만원)의 열여덟 배다. 두 통계가 어긋나는 이유는 효과가 한 달에 고르게 퍼져 있지 않기 때문이다. 표 2의 마지막 열이 이를 수요수준별로 분해한다. 혼잡한 나흘이 전체의 94.6%를 지고 있으며 그 나흘에서는 학습된 모형이 예외 없이 낮았다(4/4. 가벼운 날들은 각각 9/12, 5/8, 0/4다). 반면 나머지 24일의 평균은 -150만원이고 부트스트랩 구간이 0을 가로지른다. 날짜별 차이를 수요 층 안에서 되뺄으면 — 무대의 수요 구성이 설계로 고정돼 있으므로 이 방식이 설계를 존중한다 — 평균 차이의 95% 구간은 하루 [-3,200, -1,700]만원이고, 층을 두지 않고 되뺄으면 [-5,200, -300]만원으로 넓어지며 그 되뺄기의 99.2%가 음수로 남는다. 두 구간 모두 0을 제외하므로 방향은 일관된다. 다만 좁은 쪽은 부분적으로 구성 때문에 좁다 — 혼잡 층은 각각 이틀뿐이어서 그 안의 되뺄기는 애초에 혼잡이 얼마나 자주 일어나는가에 대한 불확실성을 표현하지 못한다. 따라서 우리가 내리는 결론은 한정적이다. 학습은 총액으로 크고 혼잡한 날에는 예외 없는 감소를 만들며, 날짜를 세는 방식은 이를 과소평가한다. 정책이 자주 이기도록이 아니라 비쌀 때 크게 줄이도록 최적화됐기 때문이고, 이는 §5.5에서 규칙에 대해 관찰한 성질과 같다. 이를 통상적인 유의수준에서 확립하려면 더 많은 날이 아니라 더 많은 혼잡한 날이 필요하다.

한편 크레인 작업순서 규칙의 상대 순위는 수요에 따라 뒤집혔다. 현행 최단 처리시간 규칙은 원활·보통 수요에서 다른 규칙보다 22-25% 비쌌으나 수요 7,500대 이상에서는 가장 싼고, 설계된 수요 비중으로 가중하면 전체적으로 가장 낮았다. 따라서 재배치 정책의 효과도 다른 작업순서 규칙 아래에서 다시 확인할 필요가 있다.

6 결론

본 연구는 컨테이너 터미널의 실시간 혼잡에 대응해 외부 트럭 작업의 야드 블록과 도착시각을 함께 재검토하는 강화학습 아키텍처를 제안했다. 재배치 제안 정책과 수락 정책을 독립적으로 구성했고, 중앙 절차가 상호 동의와 자원 제약을 확인한 뒤 배정을 일괄 반영한다. 뒤따르는 혼잡 효과의 불확실성은 한 행동만 다른 이산사건 시뮬레이션으로 만든 반사실 비용 신호로 다루었고, 운영 시각에는 학습된 신경망만으로 후보를 평가한다. 이 구성은 트럭 도착시각 협상 [3], 야드 크레인 운영 [4, 5], 다중 행위자 반사실 학습 [7, 8]을 하나의 시공간 배치 문제로 연결한다.

세 가지가 따라 나온다. 공간 배치와 시간 조정을 하나의 행동 범위 안에서 비교한다. 제안과 수락의 역할을 분리한 것은 분산 예약 협상의 논리를 실시간 재배치 정책으로 확장한 것이다 [3]. 반사실 비교는 공동 비용에서 한 행동의 기여를 학습 가능하게 만들며, 뒤따르는 대기과 장비 흐름을 즉시 이동비용과 같은 화폐 단위로

평가한다. 분기 계산이 운영에서 분리되므로 결정 경로는 작은 비용모형과 제약 확인으로 유지된다.

문헌 기반 합성환경의 관찰은 제안 구조가 시공간 재배치를 끝까지 수행하며, 혼잡한 조건에서 도착시각 조정과 학습된 선택이 비용 감소 방향을 만들 수 있음을 가리킨다. 이는 스마트항만의 실시간 정보가 모니터링에 그치지 않고 배치 행동으로 이어질 수 있다는 견해를 뒷받침한다 [1]. 행동 범위를 맞추었을 때에도 같은 방향이 유지됐으나, 도착시각 축만 놓고 보면 규칙이 더 많은 날에 낮았고 제안 정책은 총액에서만 앞섰다. 이후의 발전은 한 번에 한 축씩 정교화할 수 있다. 실제 예약 정원을 반영하면 시간 조정의 실행 가능 범위가 구체화되고, 혼잡 조건을 더 다양하게 반복하면 학습 전 모형 대비 기여의 범위가 뚜렷해진다.

6.1 한계

이 결과에는 여섯 가지 한계가 있다. 환경이 합성이다 — 규모와 변동은 보고된 범위에 맞추었으나 특정 터미널의 운영기록에 적합시킨 것이 아니고, 수요 구성과 도착곡선 계수, 그리고 네 비용 계수 중 둘은 설계값이다. 무대에서 혼잡은 드물다 — 28일 중 나흘이며 효과가 바로 거기에 있으므로 통계가 비싼 소수의 날에 기대고 있다. 학습의 몫을 확정하려면 더 많은 날이 아니라 더 많은 혼잡한 날이 필요하다. 동의 구조 자체의 기여는 분리되지 않았다 — 한쪽 동의만으로는 아무것도 확정되지 않음을 확인했으나 수락 정책의 거부권을 없애면 비용이 얼마나 달라지는지는 재지 않았다. 따라서 제안과 수락의 분리는 절제 실험이 아니라 작동 확인으로 뒷받침되는 설계 선택으로 남는다. 시간대별 예약 정원을 개방형으로 두었으므로 도착시각 관련 결과는 실행 가능한 일정이 아니라 상한 범위를 서술한다. 반사실 지평 3시간은 보고된 값이 아니라 설계에서 유도한 값이다 — 검토 창 30분, 최대 120분의 이연, 도착압력 여유 30분의 합이다. 끝으로 주 비교는 크레인 작업순서 규칙 하나를 쓰는데, 그 규칙들의 순위가 수요에 따라 뒤집히므로 다른 규칙 아래에서는 재배치 효과의 크기가 달라질 수 있다.

본 연구는 관측-제안-수락-확정-실행-반사실 학습을 하나의 재현 가능한 구조로 정리했다. 자동화 장비와 예약정보가 늘어나는 스마트항만에서, 제안 아키텍처는 실시간 혼잡 정보를 설명 가능한 자원 배치 결정으로 연결하는 기반이 될 수 있다.

References

1. Yen, B.T.H., et al.: How smart port design influences port efficiency: a DEA-Tobit approach. *Res. Transp. Bus. Manag.* **46**, 100862 (2023)
2. Chen, G., Govindan, K., Yang, Z.: Managing truck arrivals with time windows to alleviate gate congestion at container terminals. *Int. J. Prod. Econ.* **141**(1), 179–188 (2013)
3. Phan, M.-H., Kim, K.H.: Collaborative truck scheduling and appointments for trucking companies and container terminals. *Transp. Res. B* **86**, 37–50 (2016)
4. Ng, W.C., Mak, K.L.: Yard crane scheduling in port container terminals. *Appl. Math. Model.* **29**(3), 263–276 (2005)
5. Speer, U., Fischer, K.: Scheduling of different automated yard crane systems at container terminals. *Transp. Sci.* **51**(1), 305–324 (2017)
6. Petering, M.E.H., Murty, K.G.: Effect of block length and yard crane deployment systems on overall performance at a seaport container transshipment terminal. *Comput. Oper. Res.* **36**(5), 1711–1725 (2009)

7. Wolpert, D.H., Tumer, K.: Optimal payoff functions for members of collectives. *Adv. Complex Syst.* **4**(2-3), 265-280 (2001)
8. Foerster, J., et al.: Counterfactual multi-agent policy gradients. In: *AAAI*, vol. 32 (2018)
9. Kourounioti, I., Polydoropoulou, A.: Application of aggregate container terminal data for the development of time-of-day models predicting truck arrivals. *EJTIR* **18**(1) (2018)
10. Schwientek, A., Lange, A.-K., Jahn, C.: Simulation-based analysis of dispatching methods on seaport container terminals. *ARGESIM Report* **59**, 357-364 (2020)
11. Wang, W., et al.: Yard crane real-time scheduling among multi-block at terminal: a reinforcement learning based PPO approach. *Transp. Res. E* **207**, 104635 (2026)
12. Kim, S., Mowakeaa, R., Kim, S.-J., Lim, H.: Building energy management for demand response using kernel lifelong learning. *IEEE Access* **8**, 82131-82141 (2020)
13. Kleijnen, J.P.C.: Analyzing simulation experiments with common random numbers. *Manag. Sci.* **34**(1), 65-74 (1988)
14. 국토교통부: 2026년 적용 화물자동차 안전운임 고시, 제2026-402호 (2026)
15. 해양수산부: 무역항 항만시설사용료: 접안료 요율과 산정기준