

스마트 컨테이너 터미널의 시공간 재배치를 위한 강화학습 아키텍처: 독립 제안·수락 정책과 반사실 비용 학습

저자명¹

소속 기관, 주소 email@example.com

Abstract. 컨테이너 터미널에서 외부 트럭 작업의 야드 블록과 예약시각은 트럭이 도착하기 전에 정해지므로, 그 뒤에 생기는 혼잡은 고정된 계획으로 대응할 수 없다. 본 연구는 이미 통지된 작업의 블록과 도착시각을 운영 중에 함께 재검토하는 강화학습 아키텍처를 제안한다. 재배치를 요청하는 정책과 목적 블록 또는 시간대를 대신해 수락하는 정책을 독립적으로 구성하고, 양 쪽이 동의한 후보만 중앙 절차가 자원 제약 아래에서 확정한다. 작업 하나를 옮기면 뒤에 오는 트럭의 대기, 크레인 작업순서, 선박 공급 흐름이 함께 달라 지므로, 각 정책은 같은 상태에서 한 행동만 바꾼 이산사건 시뮬레이션의 비용 차이를 학습하며, 운영 시각의 추론에는 학습된 신경망만 사용한다. 평가는 선행연구가 보고한 수요 규모와 시간대별 도착 변동을 참고해 구성된 합성 도착곡선으로 외부 트럭 작업 수요를 생성하는 연속 합성환경에서 수행했다. 이 환경에서 제안 아키텍처는 재배치 없음 대비 총 운영비를 14.7% 낮췄고 같은 행동 범위를 쓰는 규칙 정책보다도 낮았다(평가 28일 중 20일, $p = 0.036$). 이 감소의 91.4%는 도착시각 조정이 만들었고, 90.5%는 가장 혼잡한 나흘에서 발생했다. 이는 시공간 재배치가 상시 개입보다 관측된 혼잡에 대한 선택적 대응으로서 값을 가진다는 것을 뜻한다.

Keywords: 스마트항만 · 컨테이너 터미널 · 트럭 도착 관리 · 야드 블록 재배치 · 반사실 학습 · 강화학습

1 서론

컨테이너 물동량은 계속 늘어 온 반면 터미널의 부지와 장비는 그만큼 늘지 못했고, 그 압박이 야드와 게이트 작업에 몰리면서 스마트항만은 투자와 연구가 함께 모이는 주제가 됐다. 그 관심은 자동화 장비에만 있지 않다. 항만 효율 연구는 자동화·지능화·환경 설계가 서로 다른 경로로 성과에 작용하므로, 터미널이 실제로 얻는 것은 관측한 정보를 운영 판단으로 어떻게 바꾸는가에 달려 있다고 본다 [1]. 그래서 관심은 장비 쪽만이 아니라 효율의 운영 측면에도 계속 머물러 있고, 그 자리에서 두 갈래의 노력이 이어지고 있다. 시간 축에서는 트럭 예약제가 도착 피크를 분산하고 터미널과 운송사가 각자의 비용에 따라 도착시각을 협의하게 한다 [2, 3]. 공간 축에서는 야드 운영 연구가 컨테이너 배치와 작업순서, 크레인 간섭의 처리를 개선해 왔다 [4-7]. 강화학습은 최근 이 계층에 실시간 크레인 배차로 들어왔다 [8].

이 노력들은 하나의 경계를 공유한다. 모두 트럭이 도착하기 전에 이미 정해진 작업 블록과 예약시각을 전제로, 그 뒤에 일어나는 일을 개선한다. 그런데 운영 중에는 특정 시간대나 블록에 수요가 몰리고 크레인 대기가 함께 변하므로, 정할




Fig. 1: 시스템 아키텍처. (A) 운영 경로는 60초마다 돌며 학습된 신경망만 쓴다. 작업은 한번 자격을 얻고, 제안 정책이 후보 중 $\arg \min$ 을 취하며, 목적지 정책이 수락 또는 거절하고, 중앙 절차는 상호 동의와 남은 용량이 모두 맞을 때만 확정한다. 아니면 원배정이 그대로 남는다. (B) 그 결정이 실행되는 환경과 결정을 평가하는 네 비용 항이다. (C) 학습 경로는 오프라인이다. 결정 직전에 뜬 스냅샷을 한 행동만 다른 병렬 세계로 다시 굴리고, 정책마다 자기 짝 안에서 중심을 뺀 누적비용 차이가 학습 목표가 된다. 운영 경로에서는 반사실 분기를 부르지 않는다.

당시에는 타당했던 배정이 더 이상 타당하지 않을 수 있다. 본 연구는 배정 자체를 다시 본다 — 이미 통지된 작업에 대해 어디에 배치할지와 언제 도착하게 할지를 하나의 실시간 결정 안에 함께 넣는다. 이런 재배치는 한 작업의 비용만 바꾸지 않는다. 작업이 옮겨지면 뒤에 오는 트럭의 대기, 크레인 작업순서, 선박 공급 흐름이 함께 달라지므로 뒤따르는 혼잡을 포함한 비용 신호가 필요하고, 차이 보상과 다중 행위자 반사실 기준선이 한 행동을 대안과 비교해 그 신호를 준다 [9, 10]. 재배치는 제안하는 쪽의 이익만으로 확정하기도 어렵다. 목적지가 그 작업을 감당할 수 있는지는 따로 판단해야 하기 때문이다. 그래서 제안과 수락을 나누고 합의와 실행 가능성은 중앙 절차에 맡긴다.

본 연구는 독립된 제안·수락 정책으로 시공간 재배치를 구성할 수 있는지, 반사실 학습을 운영 추론과 분리할 수 있는지, 이 아키텍처가 운영비를 줄이는지, 그리고 관찰된 변화에서 학습의 몫과 행동 범위의 몫을 갈라낼 수 있는지를 묻는다. 기여는 독립 정책 구조, 시공간 행동 범위, 반사실 비용 학습, 학습·운영 분리, 그리고 실행·행동 범위·학습 효과를 나누어 보고하는 분해 가능한 평가다. 2절은 이 선택들을 기존 연구 사이에 놓고, 4절은 실험환경을, 3절은 정책과 학습 신호를, 5절은 결과를 다룬다.

2 관련 연구

2.1 스마트항만과 터미널 운영

Yen 등은 자료포락분석으로 항만 효율을 측정한 뒤 그 효율 점수를 스마트항만 설계 속성에 대해 Tobit 회귀로 설명한다. 항만이 얼마나 효율적인가와 그 차이를 무엇이 설명하는가를 두 단계로 나눈 것이다. 자동화·지능화·환경 설계를 서로 다른 경로로 다루는 이 관점이, 장비 계층이 아니라 결정 계층을 연구 대상으로 삼는 이유가 된다 [1].

시간 축에서 Chen 등은 시간창으로 트럭 도착을 관리해 게이트 혼잡을 완화한다. 용량을 늘리는 대신 도착 분포의 모양을 바꾸는 접근이다 [2]. Phan과 Kim은 같은 지렛대를 쓰되 결정 주체가 하나라는 가정을 버린다. 운송사와 터미널이 각자의 비용을 그대로 쥔 채 일정과 예약을 조율하므로, 일정은 한 최적화기가 아니라 두 주체 사이에서 나온다 [3]. 이 분산 구조가 본 연구 수락 정책의 직접적인 선행이며, 수락을 공동 목적함수에 접어 넣지 않고 별도 정책으로 둔 이유이기도 하다. Kourounioti와 Polydoropoulou는 터미널 집계자료로 시간대별 트럭 도착 모형을 세워 도착이 하루 중 결코 균일하지 않음을 보인다 [11]. 그래서 도착을 옮기는 값어치는 도착 곡선의 어디에서 어디로 옮기느냐에 달려 있고, 4절의 실험환경은 평평한 도착률이 아니라 그 곡선 모양을 재현한다.

공간 축에서 Ng와 Mak은 컨테이너 터미널의 야드 크레인 스케줄링을 다루며, 크레인이 처리해야 할 작업의 순서를 정해 트럭 대기를 줄인다 [4]. Speer와 Fischer는 이를 서로 다른 자동화 야드 크레인 시스템으로 확장한다. 같은 블록에서 일하는 크레인들이 서로 간섭하므로 스케줄이 그 간섭을 풀어야 한다 [5]. Petering과 Murty는 크레인 단위가 아니라 터미널 전체의 관점을 취해, 환적 터미널의 장기 시뮬레이션으로 블록 길이와 크레인 배치가 전체 성능에 어떻게 연결되는지를 본다 [6]. 여러 주에 걸쳐 상태를 이어 가며 연속 운영하는 그 설계를 본 연구가 그대로 따른다. Schwientek 등은 항만 컨테이너 터미널의 배차 방식들을 시뮬레이션으로 비교해 그 순위가 터미널 조건에 따라 달라짐을 밝힌다 [7]. 5절이 배차 규칙을 하나로 고정해 보고하고 그 민감도를 따로 확인하는 이유가 여기에 있다.

2.2 미래비용을 반영한 최적화로서의 강화학습

배차 규칙은 행동을 지금 드는 비용으로 점수 매긴다. 본 연구가 다루는 문제의 어려움은 작업을 옮겨서 생기는 비용이 나중에, 다른 곳에서 나타난다는 데 있다 — 뒤에 오는 트럭의 대기, 크레인 작업순서, 선박 공급이 그것이다. 즉시 이동비만 값으로 매기는 규칙은 그것을 볼 수 없다. 강화학습이 이 문제의 자연스러운 도구인 이유가 바로 여기에 있다. 즉시 비용을 그 행동이 지평에 걸쳐 이끌어 내는 비용으로 바꿔 놓기 때문에, 현재의 결정이 자기 미래 결과에 책임지게 된다. Wang 등은 여러 블록에 걸친 실시간 야드 크레인 스케줄링에 PPO 기반 방법을 적용해 그런 최적화를 실행 계층 안에 놓는다 [8]. 본 연구는 블록과 도착시각을 정하는 그 위 계층을 다룬다.

이 선택에서 본 연구가 쓰는 신경망의 성질 두 가지가 따라 나온다. 첫째, 이 망은 행동에 대한 확률분포를 내놓지 않는다. 관측된 상태와 후보 행동 하나를 받아 그 후보를 확정했을 때 뒤따를 것으로 예상되는 운영비용을 내놓고, 결정은 예상비용이 가장 낮은 후보다. 즉 심층 Q-신경망이 신경망으로 행동가치를 근사하는 것과 같은 의미에서 [12] 정책경사 계열이 아니라 값 근사 계열이다. 둘째, 근사기는 작은

다층퍼셉트론이다. 다층 순방향 신경망이 일반적인 함수 근사기라는 것은 알려져 있지만 [13] 그 성질만으로 구조가 정해지지는 않는다. 선택의 근거는 자료에 있다. 입력이 영상·문장·그래프가 아니라 고정 길이의 수치표이고, 후보를 한 번에 하나씩 서로 독립으로 채점하며, 순환망이나 주의기제가 이용할 만한 시간적 순서가 입력에 없고, 라벨이 붙은 결정의 수가 블록 수에 비해 적어 큰 모형은 과적합하며, 모든 블록이 가중치 한 벌을 공유한다. 이 조건에서는 작은 퍼셉트론이 타당한 첫 선택이고, 트랜스포머나 그래프 신경망은 지금의 라벨이 감당할 수 없는 용량을 더하는 셈이다.

미래비용을 한 행위자의 결정에 실어 주는 일은 여럿이 동시에 움직일 때 더 어렵다. 지평 비용이 공동의 것이기 때문이다. Wolpert와 Tumer는 집단 구성원의 보상함수를 전체 목적과 어긋나지 않으면서도 각자의 행동에 민감하도록 구성한다. 차이 보상이다 [9]. Foerster 등은 같은 생각을 심층 다중 행위자 학습에서 구현해, 중앙 가치모형이 한 행위자의 행동을 주변화해 반사실 기준선을 만든다 [10]. 둘 다 미래 항을 학습된 가치 추정에서 얻는다. 본 연구는 같은 분해를 쓰되 미래 항을 추정이 아니라 측정으로 얻는다 — 기준선을 같은 상태에서 한 행동만 바꿔 이산사건 시뮬레이터를 다시 굴러 만들므로, 회귀 목표가 부트스트랩된 이점이 아니라 고정 지평에 걸쳐 실제로 쌓인 *원화 비용 차이*다. 이 선택의 대가는 오프라인 계산이고, 이득은 학습 신호가 목적함수와 같은 화폐 단위를 쓴다는 점이다.

Kim 등은 환경 불확실성 아래의 자원 단위 제어에 학습을 쓰는 인접 사례를 건물 수요반응에서 보이며, 실측 환경 기록과 개별 단위의 변동을 만드는 합성 매개변수를 함께 쓰되 합성 부분을 선언적으로 적는다 [14]. 4.1절이 그 방식을 따른다.

3 제안 아키텍처

3.1 기호·행동·정책

결정 간격을 $\delta = 60$ 초, 야드 블록 집합을 $\mathcal{B}$, 도착시각 이연 후보를 $\mathcal{D}$ 라 한다. 작업 i 의 현재 배정은 $z_i = (b_i, \tau_i)$ 이며 b_i 는 블록, τ_i 는 통지된 도착예정시각이다. 재배치 행동은 다음과 같다.

$$a_i = (b'_i, \Delta_i) \in \mathcal{A}_i(t), \quad z_i(a_i) = (b'_i, \tau_i + \Delta_i). \quad (1)$$

원배정 유지는 $a_i^0 = (b_i, 0)$, 블록 재배치는 $b'_i \neq b_i$, 도착시각 조정은 $\Delta_i > 0$ 이다. 두 값이 함께 바뀌는 후보도 허용한다. 반출 작업은 꺼낼 컨테이너 위치가 정해져 있으므로 블록 재배치 후보에서 제외한다.

작업의 통지시각을 n_i , 게이트 진입시각을 g_i , 최초 검토 여부를 r_i 라 하면 시점 t 에 새로 검토하는 집합은 다음과 같다.

$$\mathcal{E}_t = \{i \mid n_i \leq t < n_i + \delta, g_i > t, r_i = 0\}. \quad (2)$$

즉 아직 도착하지 않은 작업을 통지가 자격 창에 처음 들어온 한 시점에서만 검토한다.

제안 정책은 자기 블록 상태와 작업·행동 특징 o_i^P 를 이용해 예상 비용이 가장 낮은 행동을 고른다.

$$\hat{a}_i = \arg \min_{a \in \mathcal{A}_i(t)} \hat{c}_\theta^P(o_i^P, a), \quad p_i = \mathbf{1}[\hat{a}_i \neq a_i^0]. \quad (3)$$

제안이 있으면 목적 블록 또는 목표 시간대가 수락 주체가 된다. 수락 정책은 제안 메시지와 자기 상태 o_i^A 를 보고 수락과 거절의 예상 비용을 비교한다.

$$q_i = \mathbf{1}[\hat{c}_\psi^A(o_i^A, \hat{a}_i, \text{accept}) \leq \hat{c}_\psi^A(o_i^A, \hat{a}_i, \text{reject})]. \quad (4)$$

목표 자원의 남은 용량이 0이면 신경망 판단 전에 거절하며, 두 정책이 함께 동의한 후보 집합은 $\mathcal{J}_t = \{i \in \mathcal{E}_t \mid p_i q_i = 1\}$ 이다.

3.2 중앙 확정 제약

중앙 절차는 새 후보를 만들지 않고 $\mathcal{J}_t$ 안에서만 확정한다. 동의 후보를 수락 정책의 예측비용 오름차순으로 정렬하고 동점은 작업·좌표의 사전순으로 처리한다. 후보 i 의 확정 여부를 $x_i \in \{0, 1\}$, 목적 블록의 남은 슬롯을 $F_b(t)$, 예약 시간대 k 의 남은 정원을 $K_k(t)$ 라 하면 다음 제약을 만족한다.


$$x_i \leq p_i q_i, \quad \sum_{i \in \mathcal{J}_t} x_i \mathbf{1}[b'_i = b] \leq F_b(t), \quad \sum_{i \in \mathcal{J}_t} x_i \mathbf{1}[k(i) = k] \leq K_k(t), \quad \sum_{t \in \mathcal{T}} \mathbf{1}[i \in \mathcal{E}_t] \leq 1. \quad (5)$$

현행 실험에서 블록 용량 제약은 활성화돼 있다. 시간대 정원 자료가 없는 조건은 $K_k(t) = \infty$ 로 두며, 이 조건의 효과는 시간 조정 가능성의 범위로 해석한다. 확정된 새 배정은 모두 같은 시점에 일괄 반영하므로, 먼저 확정된 작업이 같은 결정 시점의 뒤 후보가 보는 상태를 바꾸지 않는다. 따라서 두 조건이 구성으로 성립한다 — 제안과 수락을 모두 지닌 후보만 확정되고, 한 작업은 정확히 한 번만 검토된다.

3.3 정책모형과 입력

3.1절의 두 함수 $\hat{c}_\theta^P$ 와 $\hat{c}_\psi^A$ 는 신경망이며, 그 역할을 분명히 해 둘 필요가 있다. 둘 다 행동에 대한 확률을 내놓지 않는다. 각각 관측된 상태와 후보 하나를 받아 그 후보를 확정했을 때 뒤따를 것으로 예상되는 비용을 내놓으므로, 정책은 표본추출된 행동이 아니라 학습된 비용의 $\arg \min$ 이고 같은 망을 후보마다 한 번씩 통과시킨다. 두 망 모두 고정 길이 특징을 후보별로 평가하는 다층퍼셉트론이며 모든 블록이 같은 가중치 한 벌을 공유한다. 제안 정책의 입력은 21차원, 수락 정책은 16차원이고 은닉층은 둘 다 64-ReLU-64-ReLU이며, 매개변수는 각각 5,633개와 5,313개로 합쳐 11,000개가 안 된다. 입력은 현재 대기·재고·크레인 잔여, 공개 도착예정시각, 경로 차이와 목표 시각 주변의 통지 물량으로 구성한다. 아직 실현되지 않은 실제 도착·완료 시각과 다른 수락 주체의 동시 응답은 입력에서 제외한다.

그림 2이 그 망 하나의 모양이다. 후보 하나가 고정 길이 벡터 $x \in \mathbb{R}^{d_{in}}$ 로 들어가 세 개의 선형층을 지나고 — 앞의 둘 뒤에는 비선형이 붙는다 — 숫자 하나로 나온다. 그 후보를 택했을 때 뒤따를 것으로 예상되는 비용이다. 이 모양이 주변 구조에 두 가지를 뜻한다. 출력이 행동 집합 위의 분포가 아니라 후보당 스칼라 하나이므로, 후보 목록이 회차마다 달라져도 — 빈 슬롯이 있는 블록들, 아직 트럭보다 앞에 있는 이연 칸들 — 목록 길이마다 다시 학습할 필요가 없다. 그리고 폭이 모든 블록에서 같으므로 가중치 한 벌을 야드 전체가 공유한다. 블록이 자기 모형을 배우는 것이 아니라, 지금 이런 상태의 블록이라면 후보를 어떻게 읽어야 하는가를 배운다. 두 정책은 d_{in} 만 다르며 제안이 21, 수락이 16이다.



$$\text{MLP}(x) = W_3 \cdot \text{GELU}(W_2 \cdot \text{GELU}(W_1 x + b_1) + b_2) + b_3$$

Fig. 2: 비용 신경망 하나의 구조. 입력은 후보 하나에 대한 고정 길이 특징 벡터이고 출력은 그 후보를 택했을 때 뒤따를 것으로 예상되는 비용이다. 따라서 한 번의 결정은 같은 망을 후보마다 한 번씩 통과시킨 뒤 $\arg \min$ 을 취한다. 제안 정책과 수락 정책은 이 모양을 공유하며 입력 차원만 각각 21과 16으로 다르다.

3.4 반사실 비용 라벨

표본 결정마다 분기 직전 상태와 난수를 복제하고 최대 세 세계를 3시간 실행한다.

$$\phi_i^F = \Phi_H(\text{관측 행동}), \quad \phi_i^P = \Phi_H(\text{제안만 반대}), \quad \phi_i^A = \Phi_H(\text{수락만 반대}), \quad H = 10,800 \text{ s.} \quad (6)$$

수락 제안이 없는 결정은 제안 비교만 만든다. 각 정책의 두 행동은 같은 평균을 빼고 100,000원으로 나누어 학습한다.

$$\bar{\phi}_i^P = \frac{\phi_i^F + \phi_i^P}{2}, \quad y_{i,F}^P = \frac{\phi_i^F - \bar{\phi}_i^P}{100,000}, \quad y_{i,P}^P = \frac{\phi_i^P - \bar{\phi}_i^P}{100,000}. \quad (7)$$

수락 정책도 (ϕ_i^F, ϕ_i^A) 에 같은 중심화를 적용한다. 평균 차감은 두 행동의 순서를 바꾸지 않으면서 공통 비용을 제거한다.

3.5 학습 설정과 운영 분리

학습일당 표본 상한은 64개 결정이고 탐색 확률은 0.50에서 0.05까지 선형으로 줄인다. 학습과 검증은 결정 단위로 80%와 20%로 나눈다. 최적화는 Adam(학습률 3×10^{-4}), 손실은 Huber($\beta = 1.0$)다. Huber 를 쓰는 이유는 반사실 차이 가운데 일부가 나머지도 훨씬 커서, 제곱오차를 쓰면 그런 표본이 적합을 지배하기 때문이다 [17]. 미니배치는 최대 256행이며 갱신 횟수는 $\max(50, \min(600, 4 \times \text{학습행 수}))$ 다. 기울기는 1.0으로 제한한다.

반사실 분기는 CPU 여러 코어에서 병렬 실행하고 그날 생성한 라벨은 당일 갱신 뒤 교체한다. 운영 평가에서는 가중치를 고정하고 탐색을 끄며 반사실 분기를 호출하지 않는다.

두 망의 학습에 24회차 동안 CPU 시간 4.7시간가 들었다. 운영 시각의 결정은 후보 하나당 위 크기의 망을 한 번 통과시키는 비용이라 함께 수행하는 제약 검사에

비해 무시할 수 있다. 이 방법의 비용은 전적으로 반사실 라벨 생성에 있으며, 그 작업은 오프라인에서 이루어져 운영 경로에 들어오지 않는다.

4 실험환경

4.1 문헌 기반 합성환경

제안한 아키텍처는 특정 터미널의 운영기록이 아니라 합성환경에서 평가한다. 규모는 2절에서 살펴본 연구들에서 가져왔다 — 20블록 [7], 블록별 복수 크레인 [5], 여러 주에 걸친 연속 운영 [6], 트럭 도착의 뚜렷한 시간대별 변동 [11], 기항량이 다른 세 선박 등급 [7], 크레인 취급시간의 삼각분포 범위 [6] 이다. 본 연구는 그 범위 안에서 21블록, 블록당 크레인 2기, 상태를 이어 가는 연속 30일, 세 선박 등급, 크레인 서비스시간 180초로 고정했고, 도착곡선은 4.3절에서 다룬다. 이 고정값들은 본 연구의 설계 선택이며, 인용은 그 값이 기존 연구의 모형 범위 안에 놓인다는 근거일 뿐 특정 항만의 운영자료에서 왔다는 뜻이 아니다.

4.2 터미널과 시간 설정

야드는 21블록이고 블록마다 야드 크레인 2기를 두어 모두 42기다. 블록 용량은 1,440 슬롯이며 시작 점유율은 65%다. 게이트와 안벽은 반대쪽에 있는 1차원 배치이고, 결정 간격은 60초다. 운영은 30일 연속이며 가운데 28일을 비교한다. 크레인 작업순서는 실제 작업을 우선하고 그 안에서 예상 처리시간이 짧은 작업을 먼저 수행한다. 하루는 터미널이 자정에 멈춘다는 뜻이 아니라 비용을 나누는 절단면이다. 야드 재고, 대기열, 크레인 상태와 미완료 작업은 다음 날로 이어지며, 첫날과 마지막날이 그 경계를 잇는다.

4.3 외부 트럭 작업 수요와 도착 과정

외부 트럭 작업 수요는 선행연구가 보고한 범위를 복제/한 것이 아니라 그것을 참고해 구성했다. 선행연구가 뒷받침하는 것은 터미널이 이 정도 수요 규모에서 운영된다는 것과 트럭 도착이 하루 중 크게 변동한다는 사실이며 [11], 여기서 쓰는 구체적 곡선은 본 연구의 합성 구성이다. 일일 수요 수준은 $\{3,500, 5,000, 7,500, 12,500, 15,000\}$ 대 위의 이산분포에서 확률 $\{0.30, 0.30, 0.25, 0.10, 0.05\}$ 로 뽑는다(그림 3a). 앞의 셋은 원활·보통·높은 수요이고 뒤의 둘은 혼잡·초혼잡 조건이다. 하루 안에서 각 작업의 통지 시각은 전체 물량의 38%를 담는 균등 기저와 나머지를 담는 가우시안 성분 셋을 결합한 도착밀도 $f(t)$ 에서 생성한다(그림 3b).

$$f(t) = 0.38 U(0, 24) + 0.62 \sum_{m=1}^3 w_m \mathcal{N}(t; \mu_m, \sigma_m^2), \quad (8)$$

여기서 (μ_m, σ_m, w_m) 은 각각 $(10, 1.5, .317)$, $(15, 2.5, .633)$, $(21, 1, .05)$ 이고 시간 단위는 시(hour)다. 균등 기저가 야간에도 도착을 0으로 두지 않으므로, 날 경계를 넘어 이어지는 야드 상태가 빈 밤의 산물이 아니다. 봉우리의 위치와 폭과 가중은 수요수준별 혼잡 민감도를 비교할 수 있도록 정한 설계값이지 특정 터미널에 적합시킨 추정값이 아니다. 학습과 평가는 같은 곡선 형태를 쓴다. 둘 사이에서 다른 것은 수요 수준과 난수뿐이므로, 형태가 다른 도착곡선에 대해서는 정책을 시험하지 않았다.




Fig. 3: 외부 트럭 작업 수요. (a) 다섯 개의 일일 수요 수준과 각각이 뽑힐 확률이며 날마다 독립으로 추정한다. (b) 하루 12,500대 조건의 시간대별 도착 과정으로, 균등 기저와 가우시안 성분 셋을 이들이 합쳐 이루는 곡선 아래에 따로 그렸다. 선행연구가 뒷받침하는 것은 수요 규모와 도착이 하루 중 균일하지 않다는 사실이고, 혼합의 형태는 본 연구의 구성이다.

4.4 선박과 안벽 작업

선박은 세 등급으로 나뉘었다 — 소형 (50,000 GT · 3,000 TEU · STS 2기 · 시간당 유회비용 149,500원), 중형 (100,000 GT · 7,500 TEU · 4기 · 299,000원), 대형 (150,000 GT · 14,000 TEU · 6기 · 448,500원). 용량 C TEU 인 선박의 기항 작업량은 $u \sim U[0.15, 0.30]$ 에 대해 $C \cdot u$ 로 뽑았고, 하루 구성은 소형 2척과 중형 1척이며 대형 1척을 30% 확률로 더했다. STS 1기의 처리율은 27.5 move/h로 두며 이는 문헌의 $24 \cdot 30 \cdot 36$ move/h 범위 안에 있다 [7]. 여러 STS의 막힘은 합산한 뒤 배정 대수로 나누어 선박 단위 유회시간으로 환산한다. 야드 쪽에서 크레인 1기의 기준 서비스 시간은 180초/move이므로 이론상 총 이동능력은 $\mu_{YC} = 21 \times 2 \times 3600/180 = 840$ move/h다. move/h는 컨테이너 이동 횟수이며 트럭 건수와 다르다. 트럭 한 건은 이동과 재취급을 여러 번 요구할 수 있고 실제 서비스시간도 위치와 작업 종류에 따라 변하므로, 이동 단위와 트럭 단위를 구분해 보고한다.

4.5 비용함수

날짜 구간 $[d, d+1)$ 의 총비용은 네 항의 합으로 정의한다.

$$\Phi_d = C_{wait,d} + C_{move,d} + C_{rehandle,d} + C_{vessel,d}. \quad (9)$$

트럭 체류는 시간당 40,000원이며 1시간 초과분에 같은 단가를 더한다. 안전운임을 화폐 기준점으로 사용하고 시간 환산은 연구값이다 [15]. 추가 크레인 이동은 작업시간당 60,000원, 재취급은 회당 2,000원으로 두며 둘 다 연구 설계값이다. 선박 유회는 GT·시간당 2.99원으로, 접안 초과요율 29.9원/10GT·시간을 환산했다 [16]. 트럭 i 의 체류시간을 h_i , 추가 크레인 작업시간을 m , 재취급 횟수를 R , 선박 v 의 정책 관련 유회시간을 T_v 라 하면 다음과 같다.

$$C_{wait} = \sum_i 40,000 \{h_i + \max(0, h_i - 1)\}, C_{move} = 60,000 m, C_{rehandle} = 2,000 R, C_{vessel} = \sum_v 2.99 GT_v T_v. \quad (10)$$

접이안과 검역처럼 재배치 정책이 바뀌지 않는 구조적 선박 시간은 진단값으로 분리한다. 네 비용 항은 같은 날짜 경계의 누적값 차이로 계산한다.

이렇게 정한 환경의 성질 두 가지를 학습 30일 실행에서 측정했다. 첫째, 비용은 대기가 지배한다. C_{wait} 가 총비용의 96.4% 이고 재취급 2.2%, 선박 유탄 1.2%, 추가 크레인 이동 0.1% 다. 따라서 Φ 로 내린 판단은 규정에서 가져온 안전운임 계수 [15] 가 사실상 좌우하며, 문헌값이 아니라 설계값인 나머지 두 계수에는 둔감하다. 둘째, 대기의 비중과 서비스 수준이 수요와 함께 급격히 나빠진다. 대기는 하루 3,500대에서 비용의 83.2%, 7,500대에서 91.7%, 15,000대에서 99.1%로 올라가며 다른 항을 모두 밀어낸다. 한 달 전체로는 평균 체류시간 0.89시간, 90분위 2.01시간이고 트럭 작업 206,904건 중 5.0%가 통지된 날 안에 끝나지 않았다. 그런데 그 90분위는 가장 한산한 날 0.79시간에서 가장 붐비는 날 7.49시간까지 9.5배로 벌어진다. 즉 혼잡한 날은 단지 더 비싼 것이 아니라 비싼 이유가 다르며, 재배치 정책이 이용하도록 요구받는 성질이 바로 이것이다.

5 실험결과

5.1 결과의 범위

아래 결과는 학습과 겹치지 않는 난수시드 9,900,950으로 만든 30일 연속 진단 실행의 가운데 28일이다. 가중치를 고정하고 탐색확률을 0으로 두었으며, 같은 날짜의 모든 정책은 같은 트럭·선박·서비스 난수를 공유했다. 날짜마다 네 비용 항, 수요수준, 거래 유형, 미완료 작업을 저장한다. 소스코드와 정책별 원자료, 그림 스크립트를 함께 공개한다.

5.2 아키텍처 작동 확인

네 조건 — 제안과 수락을 서로 다른 모형이 판단하는 것, 한쪽 동의만으로 확정된 재배치가 0건인 것, 미래의 실제 도착·완료시각이 정책 입력에 없는 것, 날짜 경계에서 상태가 초기화되지 않는 것 — 은 구현과 확정 제약, 자동 시험에서 따라 나온다. 나머지 둘은 실행 자체에서 확인됐다. 고정정책 평가 중 반사실 호출이 0회였고, 행동을 바꾸지 않은 분기가 본 실행의 행동과 비용을 재현하는 동일성 검사가 반사실 라벨이 있는 곳에서 4/4 통과했다.

5.3 정책별 날짜 짝비교

모든 정책은 같은 난수 위에서 굴린다. 공통 난수에 관한 Kleijnen의 분석을 따른 것으로, 두 정책의 차이를 시뮬레이션 잡음으로 읽지 않기 위해서다 [18]. 비용 차이는 제안 정책에서 비교 정책을 뺀 값이며, 음수이면 제안 정책의 비용이 더 낮다. 날짜를 독립 비교 단위로 두고 양측 부호검정을 사용했다(표 1). 같은 짝에 대해 부호뿐 아니라 날짜별 차이의 크기까지 함께 쓰는 월콕슨 부호순위검정을 적용해도 결론은 어디서도 달라지지 않으며 오히려 약해지지도 않는다(모든 규칙 정책에 대해 $p \leq 0.017$).

28일 총비용은 재배치 없음이 100.0억원, 제안 정책이 85.2억원으로 14.71억원 (14.7%) 감소했다. 정책별 감소율은 표 1에 있다. 위 규칙 네 정책은 블록 재배치만 사용하므로 이 비교는 아키텍처 전체의 가능성을 나타내며, 행동 범위를 맞춘 비교는 §5.5에서 따로 다룬다. 제안 정책의 비용이 더 큰 날은 수가 적고 차이도 작은 반면, 가장 크게 줄인 날은 모두 수요가 혼잡한 날이다.

Table 1: 같은 28일 위의 모든 정책을 비용 감소율 순으로 정렬했다. 오른쪽 두 열은 각 정책을 제안 정책과 날짜별로 건준 결과다. 사용 행동 열을 따라 내려 읽으면 규칙이 보인다 — 도착시각을 쓰는 정책은 모두 비용을 낮추고, 블록 재배치만 쓰는 정책은 모두 0 근처에 머문다.

정책	사용 행동	감소율	제안 정책 대비	
			낮은 날	p
제안 정책	블록 + 시각	+14.72%	—	—
제안 정책 (시각만)	시각	+13.44%	—	—
학습 전 모형	블록 + 시각	+7.97%	18/28	0.185
규칙: 한산한 시간대	시각	+3.41%	—	—
규칙: 한산한 블록 + 시간대	블록 + 시각	+1.51%	20/28	0.036
규칙: 최소 여유시간	블록	+0.53%	20/28	0.036
규칙: 선착순	블록	+0.17%	22/28	0.004
규칙: 최단 처리시간	블록	+0.05%	21/28	0.013
규칙: 순이득	블록	-0.48%	21/28	0.013
제안 정책 (블록만)	블록	-1.31%	—	—
재배치 없음	—	0.00%	26/28	<0.001

5.4 수요수준과 행동의 분해

표 2가 감소를 수요수준별로 분해한다. 전체의 90.5%가 수요 12,500대와 15,000대인 나홀에서 나왔고, 이는 제안 아키텍처를 상시 개입보다 *혼잡이 관측될 때 선택적으로 개입하는 정책*으로 발전시킬 근거가 된다. 같은 28일에서 한 번에 한 행동만 허용하면 두 기여가 갈라진다 — 도착시각 조정이 전체 감소의 91.4%를 설명하고 그 대부분이 그 나홀에서 나오는 반면, 블록만 허용한 조건은 원활·보통 수요에서 1.24억원을 줄이지만 가장 높은 수요에서 비용을 올려 합계로는 1.31억원 증가한다. 따라서 정책은 수요수준에 따라 공간 행동과 시간 행동의 사용 비중을 조절하는 방향으로 최적화될 수 있다. 이 진단 실행에서 시간대별 예약 정원은 개방형이었으므로 도착시각 관련 수치는 시간 이동이 제공할 수 있는 *가능성 범위*이며, 유한 정원을 넣은 민감도 분석으로 적용 범위를 정교화할 수 있다.

5.5 같은 행동 범위를 쓰는 규칙 정책

§5.4는 규칙에 같은 행동을 주면 어떻게 되는가라는 물음을 남긴다. 공간 축에서 쓰던 *가장 한산한 곳* 기준을 시간 축으로 옮겨 규칙 둘을 추가했다. 새 파라미터를 도입하지 않고 기준이 적용되는 축만 바꾼 것이며, 다른 규칙과 같은 혼잡 조건을 공유한다. 표 1가 이들을 다른 정책들 사이에 놓는다. 세 가지가 따라 나온다. 규칙 만으로도 도착시각 조정은 비용을 유의하게 낮추므로(재배치 없음 대비 +3.41%, $p = 0.0125$) 그 행동 자체가 값을 가진다. 행동 범위를 맞추어도 제안 정책이 규칙 보다 여전히 싸다(20/28, $p = 0.036$). 그런데 도착시각 축만 보면 *규칙이 더 많은 날에* 낮았고(제안 정책 8/28) 총액은 제안 정책이 약 4배 낮았다. 원활한 수요에서는 규칙이 근소하게 낮고 혼잡한 날에는 제안 정책이 3.8–5.6배 낮기 때문이다. 학습된 선택은 *자주 이기는 방향이 아니라 비싼 날에 크게 줄이는 방향으로* 최적화됐으며,

Table 2: 감소가 어디서 나오는가 — 수요수준별, 재배치 없음 대비(억원). 셋째에서 다섯째 열은 한 번에 한 행동만 허용한 조건이고, 마지막 열은 그 감소 중 학습이 보태는 몫으로 학습된 모형을 학습 전 모형과 견준 값이다. 도착시각 조정이 감소의 거의 전부를 만들며 그것도 혼잡한 나홀에서 나오고, 블록 재배치는 수요가 가벼울 때 도움이 되다가 가장 높을 때 손해로 돌아서며, 학습의 몫도 같은 혼잡일 양상을 따른다.

일일 수요	일 날 수	두 행동 모두	시각 만	블록 만	학습의 몫
3,500	12	0.47	-0.13	0.57	0.56
5,000	8	0.60	0.29	0.67	0.29
7,500	4	0.32	0.08	0.00	-0.49
12,500	2	6.11	5.73	-0.14	1.44
15,000	2	7.22	7.47	-2.41	4.95
합계	28	14.71	13.44	-1.31	6.75
전체 중 비중		100%	91.4%	—	45.9%

두 지표를 함께 보고해야 이 성질이 드러난다. 두 행동을 모두 쓰는 규칙도 혼잡 수요에서 약해져 §5.4의 성질을 그대로 재현하며, 이는 그것이 특정 정책이 아니라 행동 자체에 속함을 시사한다.

5.6 학습 효과와 작업순서 민감도

비용 비교에 앞서 적합 자체를 본다. 30회차 동안 제안망의 Huber 손실은 학습 결정에서 0.079에서 0.029로, 처음 보는 결정에서 0.268에서 0.119로 내려갔고, 수락망은 각각 0.171에서 0.027로, 0.315에서 0.136으로 내려갔다(처음 다섯 회차와 마지막 다섯 회차의 평균이며 목표는 10만원 단위다). 즉 검증 손실이 학습과 함께 내려가므로 적합이 보지 않은 결정으로도 이어진다. 다만 끝에서도 검증 손실이 학습 손실의 약 네 배인데, 이는 회차당 라벨이 56건 남짓인 표본이 허용하는 수준이며 모형을 작게 유지한 또 하나의 이유다. 반사실 차이가 정확히 0이던 결정의 비율은 탐색이 줄면서 51.4%에서 37.6%로 내려갔고, 반사실 세계는 모두 4,671개를 굴렸다.

재배치 없음 100.0억원에서 학습 전 모형은 92.0억원, 학습된 모형은 85.2억원이었다. 학습 뒤 추가 감소는 6.75억원으로 전체 감소의 45.9%다. 그런데 날짜를 세면 학습된 모형이 28일 중 18일만 낮았고($p = 0.1849$), 날짜별 차이의 평균(-2,410만원)은 중앙값(-130만원)의 열여덟 배다. 두 통계가 어긋나는 이유는 효과가 한 달에 고르게 퍼져 있지 않기 때문이다. 표 2의 마지막 열이 이를 수요수준별로 분해한다. 혼잡한 나홀이 전체의 94.6%를 지고 있으며 그 나홀에서는 학습된 모형이 예외 없이 낮았다(4/4. 가벼운 날들은 각각 9/12, 5/8, 0/4다). 반면 나머지 24일의 평균은 -150만원이고 부트스트랩 구간이 0을 가로지른다. 날짜별 차이를 수요 층 안에서 되뺏으면(무대의 수요 구성이 설계로 고정돼 있으므로 이 방식이 설계를 존중한다) 평균 차이의 95% 구간은 하루 [-3,200, -1,700]만원이고, 층을 두지 않으면 [-5,200, -300]만원으로 넓어지며 되뺏기의 99.2%가 음수로 남는다. 두 구간 모두 0을 제외하지만, 좁은 쪽은 혼잡 층이 각각 이틀뿐이라 부분적으로 구성 때문에 좁다. 따라서 결론은 한정적이다. 학습은 총액으로 크고 혼잡한 날에는 예외 없는 감소를 만들며, 날짜를 세는 방식은 이를 과소평가한다. 정책이 자주 이기도록이 아니라 비쌀 때 크게 줄이도록 최적화됐기 때문이고, 이는 §5.5에서 규칙에 대해

관찰한 성질과 같다. 통상적인 유의수준에서 확립하려면 더 많은 날이 아니라 더 많은 혼잡한 날이 필요하다.

한편 크레인 작업순서 규칙의 상대 순위는 수요에 따라 뒤집혔다. 현행 최단 처리시간 규칙은 원활·보통 수요에서 다른 규칙보다 22~25% 비쌌으나 수요 7,500 대 이상에서는 가장 싼고, 설계된 수요 비중으로 가중하면 전체적으로 가장 낮았다. 따라서 재배치 정책의 효과도 다른 작업순서 규칙 아래에서 다시 확인할 필요가 있다.

6 결론

본 연구는 이미 통지된 외부 트럭 작업의 야드 블록과 도착시각을 운영 중에 함께 재검토하는 강화학습 아키텍처를 제안했다. 분산 예약 협상 [3]과 야드 크레인 운영 [4, 5]을 하나의 시공간 배치 문제로 확장한 것이다. 재배치의 비용은 나중에, 다른 곳에서 나타나므로 각 정책은 즉시 이동비가 아니라 고정 지평에 걸쳐 켜 반사실 비용 차이로 학습한다. 다중 행위자 반사실 학습 [9, 10]이 운영 결정에 들어오는 통로가 이것이다. 그 분기 계산을 운영에서 떼어 두었으므로 운영 경로는 작은 비용모형과 제약 확인으로 남는다.

무엇 기반 합성환경의 관찰은 제안 구조가 시공간 재배치를 끝까지 수행하며, 혼잡한 조건에서 도착시각 조정과 학습된 선택이 비용 감소 방향을 만들 수 있음을 가리킨다. 이는 스마트항만의 실시간 정보가 모니터링에 그치지 않고 배치 행동으로 이어질 수 있다는 견해를 뒷받침한다 [1]. 행동 범위를 맞추었을 때에도 같은 방향이 유지됐으나, 도착시각 축만 놓고 보면 규칙이 더 많은 날에 낮았고 제안 정책은 총액에서만 앞섰다. 이후의 발전은 한 번에 한 축씩 정교화할 수 있다. 실제 예약 정원을 반영하면 시간 조정의 실행 가능 범위가 구체화되고, 혼잡 조건을 더 다양하게 반복하면 학습 전 모형 대비 기여의 범위가 뚜렷해진다.

6.1 한계

이 결과에는 일곱 가지 한계가 있다. 환경이 합성이다 — 규모와 변동은 보고된 범위에 맞추었으나 특정 터미널의 운영기록에 적합시킨 것이 아니고, 수요 구성과 도착곡선 계수, 그리고 네 비용 계수 중 둘은 설계값이다. 게다가 학습과 평가가 같은 도착곡선 형태를 공유하며 수요 수준과 난수만 다르므로, 처음 보는 도착 형태로 정책이 옮겨 간다는 것은 보이지 못했다. 학습 중에 봉우리 시각과 폭을 범위 안에서 변화시키고 학습에 쓰지 않은 곡선으로 평가하는 것이 자연스러운 다음 단계다. 무대에서 혼잡은 드물다 — 28일 중 나흘이며 효과가 바로 거기에 있으므로 통계가 비싼 소수의 날에 기대고 있다. 학습의 몫을 확정하려면 더 많은 날이 아니라 더 많은 혼잡한 날이 필요하다. 동의 구조 자체의 기여는 분리되지 않았다 — 한쪽 동의만으로는 아무것도 확정되지 않음을 확인했으나 수락 정책의 거부권을 없애면 비용이 얼마나 달라지는지는 재지 않았다. 따라서 제안과 수락의 분리는 절제 실험이 아니라 작동 확인으로 뒷받침되는 설계 선택으로 남는다. 시간대별 예약 정원을 개방형으로 두었으므로 도착시각 관련 결과는 실행 가능한 일정이 아니라 상한 범위를 서술한다. 반사실 지평 3시간은 보고된 값이 아니라 설계에서 유도한 값이다 — 검토 창 30분, 최대 120분의 이연, 도착압력 여유 30분의 합이다. 끝으로 주 비교는 크레인 작업순서 규칙 하나를 쓰는데, 그 규칙들의 순위가 수요에 따라 뒤집히므로 다른 규칙 아래에서는 재배치 효과의 크기가 달라질 수 있다.

본 연구는 관측-제안-수락-확정-실행-반사실 학습을 하나의 재현 가능한 구조로 정리했다. 자동화 장비와 예약정보가 늘어나는 스마트항만에서, 제안 아키텍처는 실시간 혼잡 정보를 설명 가능한 자원 배치 결정으로 연결하는 기반이 될 수 있다.

References

1. Yen, B.T.H., et al.: How smart port design influences port efficiency: a DEA-Tobit approach. *Res. Transp. Bus. Manag.* **46**, 100862 (2023)
2. Chen, G., Govindan, K., Yang, Z.: Managing truck arrivals with time windows to alleviate gate congestion at container terminals. *Int. J. Prod. Econ.* **141**(1), 179–188 (2013)
3. Phan, M.-H., Kim, K.H.: Collaborative truck scheduling and appointments for trucking companies and container terminals. *Transp. Res. B* **86**, 37–50 (2016)
4. Ng, W.C., Mak, K.L.: Yard crane scheduling in port container terminals. *Appl. Math. Model.* **29**(3), 263–276 (2005)
5. Speer, U., Fischer, K.: Scheduling of different automated yard crane systems at container terminals. *Transp. Sci.* **51**(1), 305–324 (2017)
6. Petering, M.E.H., Murty, K.G.: Effect of block length and yard crane deployment systems on overall performance at a seaport container transshipment terminal. *Comput. Oper. Res.* **36**(5), 1711–1725 (2009)
7. Schwientek, A., Lange, A.-K., Jahn, C.: Simulation-based analysis of dispatching methods on seaport container terminals. *ARGESIM Report* **59**, 357–364 (2020)
8. Wang, W., et al.: Yard crane real-time scheduling among multi-block at terminal: a reinforcement learning based PPO approach. *Transp. Res. E* **207**, 104635 (2026)
9. Wolpert, D.H., Tumer, K.: Optimal payoff functions for members of collectives. *Adv. Complex Syst.* **4**(2–3), 265–280 (2001)
10. Foerster, J., et al.: Counterfactual multi-agent policy gradients. In: *AAAI*, vol. 32 (2018)
11. Kourounioti, I., Polydoropoulou, A.: Application of aggregate container terminal data for the development of time-of-day models predicting truck arrivals. *EJTIR* **18**(1) (2018)
12. Mnih, V., et al.: Human-level control through deep reinforcement learning. *Nature* **518**(7540), 529–533 (2015)
13. Hornik, K.: Approximation capabilities of multilayer feedforward networks. *Neural Netw.* **4**(2), 251–257 (1991)
14. Kim, S., Mowakeaa, R., Kim, S.-J., Lim, H.: Building energy management for demand response using kernel lifelong learning. *IEEE Access* **8**, 82131–82141 (2020)
15. 국토교통부: 2026년 적용 화물자동차 안전운임 고시, 제2026-402호 (2026)
16. 해양수산부: 무역항 항만시설사용료: 접안료 요율과 산정기준
17. Huber, P.J.: Robust estimation of a location parameter. *Ann. Math. Statist.* **35**(1), 73–101 (1964)
18. Kleijnen, J.P.C.: Analyzing simulation experiments with common random numbers. *Manag. Sci.* **34**(1), 65–74 (1988)